


Regresión lineal

Ignacio Díaz Oreiro

CI0131. Diseño de Experimentos



Agradecimiento a la profesora Dra. Kryscia Ramírez Benavides, por facilitar material usado en esta presentación.



Introducción

- A veces necesitamos hacer conjeturas sobre el futuro.
- Por ejemplo, una empresa puede querer estimar cuántos empleados deberían estar trabajando en cada turno después de una gran campaña publicitaria.
- Los administradores de un sistema creen que sus servidores web recibirán mucho tráfico pronto y desean agregar servidores a sus clústeres. ¿Pero cuántos?
- Este tipo de preguntas se pueden responder utilizando datos y técnicas como la regresión lineal.

Regresión lineal

Introducción

La forma de regresión más utilizada es llamada regresión lineal. Podemos usar la regresión cuando tenemos tres cosas:

Un valor que
queremos predecir

La cantidad de empleados que necesitaremos en un turno

La cantidad de servidores que debemos agregar a un clúster

Una relación
conocida entre
variables

Con más empleados, podemos atender a más clientes y vender más productos.

Cuando tenemos más servidores, podemos manejar más tráfico web.

Datos


Por lo general, datos históricos.

¿Cuántos clientes puede atender un empleado y cuántas vistas de página puede manejar un solo servidor web en un minuto?

Regresión lineal


Introducción

- Visualicemos la relación entre variables del primer caso:
- El eje x representa el número de artículos vendidos.
- La tienda vende cientos de artículos por día, por lo que usaremos una escala de cero a 1000.
- El eje y representa la cantidad de empleados por turno, que siempre es menor a 10.



Introducción


- Tracemos datos históricos.
- Para cada turno, sabemos cuántos artículos se vendieron y cuántos empleados estaban trabajando.
- Podemos comenzar a ver una relación: somos capaces de vender más artículos cuando tenemos más empleados.



Regresión lineal

Introducción


- En la regresión lineal, podemos encontrar una línea que atraviesa los puntos de datos de una manera que captura la tendencia general.
- Ahora, queremos saber cuántos empleados necesitamos si esperamos vender una cierta cantidad de artículos.
- Podemos usar la fórmula de esta recta para hacer predicciones.



Regresión lineal

Introducción


- Por ejemplo, si esperamos vender 750 artículos, tendríamos alrededor de ocho empleados trabajando en ese turno.
- Se puede ver que descubrir cómo trazar la recta a través de los puntos de datos es un desafío clave.
- ¿Cómo se hace eso?



Regresión lineal

Introducción


- Veamos un ejemplo simple, una gráfica de solo dos puntos.
- Se puede dibujar una recta entre los dos puntos, por lo que nuestra línea de regresión se ve así.
- ¿Y si añadimos un tercer punto?
- En este caso, el tercer punto está en la misma recta, por lo que no tenemos que hacer ningún cambio.



Regresión lineal


Introducción

- Pero, ¿y si agregamos puntos que no caen en la recta?
- No hay una línea recta que pase por los cinco puntos.
- Debemos arreglarlo trazando una línea que pase lo más cerca posible de todos los puntos.



Introducción


- Con una línea que está cerca de todos los puntos, podemos medir la distancia de cada punto a la línea de regresión.
- Si sumamos la longitud de cada una de estas distancias, podemos tener una medida de qué tan bien se ajusta la línea de regresión a los datos.



Regresión lineal


Introducción

- Queremos que esta distancia total sea lo más pequeña posible.
- Llamamos a la suma de la distancia el error total en el ajuste de una línea de regresión, y queremos minimizar eso.
- Las funciones de regresión lineal están diseñadas para ajustarse a las líneas de regresión y minimizar este error.



Introducción


- Podemos definir una línea usando una fórmula que hace referencia a la intersección y, o el punto en el que una línea cruza el eje y.
- En este caso, la intersección con y es aproximadamente 2.41.
- La pendiente nos dice qué tan rápido sube o baja la línea a medida que se aleja del punto de intersección y.
- En este caso la pendiente es 0.0033.



Regresión lineal

Introducción

- Con la intersección en y y la pendiente, usamos la fórmula de la recta: $y = m \cdot x + b$.
 - y es un valor que está prediciendo
 - m es la pendiente
 - x es un valor que estamos aportando para hacer la predicción
 - b es la intersección.
- Si queremos predecir el número de empleados que deben trabajar para acomodar la venta de 1000 artículos, evaluamos $0.0033 \cdot 1000 + 2.41 = 5.71$.
- Por lo tanto, se necesitarán aproximadamente 6 empleados disponibles.



Correlación lineal y regresión lineal

- La correlación lineal y la regresión lineal simple son métodos estadísticos que estudian la relación lineal existente entre dos variables.
- La correlación cuantifica qué tan relacionadas están dos variables, mientras que la regresión lineal consiste en generar una ecuación (modelo) que, basándose en la relación existente entre ambas variables, permita predecir el valor de una a partir de la otra.

Regresión lineal

Correlación lineal y regresión lineal

- El cálculo de la correlación entre dos variables es independiente del orden o asignación de cada variable a X e Y, mide únicamente la relación entre ambas sin considerar dependencias.
- En el caso de la regresión lineal, el modelo varía según qué variable se considere dependiente de la otra (lo cual no implica necesariamente causa-efecto).

Regresión lineal

Correlación lineal y regresión lineal

- A nivel experimental, la correlación se suele emplear cuando ninguna de las variables se ha controlado, simplemente se han medido ambas y se desea saber si están relacionadas.
- En el caso de estudios de regresión lineal, es más común que una de las variables se controle (tiempo, tasa de éxito, temperatura...) y se mida la otra.

Regresión lineal

Correlación lineal y regresión lineal

- Por norma general, los estudios de correlación lineal preceden a la generación de modelos de regresión lineal.
- Primero se analiza si ambas variables están correlacionadas y, en caso de estarlo, se procede a generar el modelo de regresión.

Correlación lineal

- La correlación lineal estudia la relación lineal existente entre dos variables continuas y para ello es necesario disponer de parámetros que permitan cuantificar dicha relación.
- Uno de estos parámetros es la covarianza, que indica el grado de variación conjunta de dos variables aleatorias:

$$Cov(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

- Siendo $\bar{x}$ e $\bar{y}$ la media de cada variable y x_i e y_i el valor de las variables para la observación i .

Coeficientes de correlación

$$Cov(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

- La covarianza depende de las escalas en que se miden las variables estudiadas, por lo tanto, no es comparable entre distintas escalas de variables.
- Para poder hacer comparaciones se estandariza la covarianza, generando lo que se conoce como *coeficientes de correlación*.
- Existen diferentes tipos, de entre los que destacan el *coeficiente de Pearson*, *Rho de Spearman* y *Tau de Kendall*.

Coeficientes de correlación

- Todos estos coeficientes de correlación varían entre +1 y -1, siendo +1 una correlación positiva perfecta y -1 una correlación negativa perfecta.
- Se emplean como medida de fuerza de asociación (tamaño del efecto):
 - 0: asociación nula
 - 0.1: asociación pequeña
 - 0.3: asociación mediana
 - 0.5: asociación moderada
 - 0.7: asociación alta
 - 0.9: asociación muy alta

Correlación lineal

Coeficientes de correlación

- La correlación de Pearson funciona bien con variables cuantitativas que tienen una distribución normal. Algunos autores afirman que sigue siendo bastante robusta a pesar de la falta de normalidad. Es más sensible a los valores extremos (outliers) que las otras dos alternativas.
- La correlación de Spearman se emplea cuando los datos son ordinales, de intervalo, o bien cuando no se satisface la condición de normalidad para variables continuas y los datos se pueden transformar a rangos. Es un método no paramétrico.

Correlación lineal

Coeficientes de correlación

- La correlación de Kendall es otra alternativa no paramétrica para el estudio de la correlación que trabaja con rangos. Se emplea cuando se dispone de pocos datos y muchos de ellos ocupan la misma posición en el rango.

Coeficientes de correlación

- Además del valor obtenido para el coeficiente de correlación, es necesario calcular su significancia.
- Solamente si el p-value es significativo se puede aceptar que existe correlación, y esta correlación será de la magnitud que indique el coeficiente.
- Por muy cercano que sea el valor del coeficiente de correlación a $+1$ ó -1 , si no es significativo, se ha de interpretar que la correlación de ambas variables es 0, ya que el valor observado puede deberse a simple aleatoriedad.

Coeficientes de correlación

- El test paramétrico de significancia estadística empleado para el coeficiente de correlación es el t-test.
- Al igual que con muestras, por un lado está el parámetro estimado (el coeficiente de correlación) y por otro su significancia al considerar la población entera.
- Si se calcula el coeficiente de correlación entre X e Y en diferentes muestras de una misma población, el valor va a variar dependiendo de las muestras utilizadas.
- Por esto se tiene que calcular la significancia de la correlación obtenida y su intervalo de confianza.

Coeficientes de correlación

- Para esta prueba de hipótesis
 - H_0 considera que las variables son independientes (coeficiente de correlación poblacional = 0)
 - H_1 considera que existe relación (coeficiente de correlación poblacional $\neq 0$)
- La correlación lineal entre dos variables, además del valor del coeficiente de correlación y de su significancia, también tiene un tamaño de efecto asociado, conocido como coeficiente de determinación R^2 .

Correlación lineal

Coeficientes de correlación

- Se interpreta como la cantidad de varianza de Y explicada por X.
- En el caso del coeficiente de Pearson y el de Spearman, el coeficiente de determinación R^2 se obtiene elevando al cuadrado el coeficiente de correlación.
- En el caso de Kendall no se puede calcular de este modo dado que usa un enfoque no paramétrico y no midiendo la magnitud de diferencias.

Regresión lineal simple

- La regresión lineal procura modelar la relación entre variables, mediante el ajuste de una ecuación lineal a los datos observados.
- Si en regresión lineal se cuenta con dos variables, una variable de respuesta y una variable independiente, se conoce como regresión lineal simple (SLR).
- La regresión lineal simple consiste en generar un modelo de regresión (ecuación de una recta) que permita explicar la relación lineal que existe entre dos variables.
- A la variable dependiente o respuesta se le identifica como y , y a la variable predictora o independiente como x .

Regresión lineal simple

- El modelo de regresión lineal simple (SLR) se describe con la ecuación:

$$y = \beta_0 + \beta_1 x + \epsilon$$

Siendo: β_0 la intersección con el eje y

β_1 la pendiente

ϵ el error aleatorio

y la variable de respuesta

x la variable predictora o independiente

- El error aleatorio ϵ recoge el efecto de todas aquellas variables que influyen en y pero que no se incluyen en el modelo como predictores.

Regresión lineal simple

- La regresión lineal se utiliza para cuantificar la relación entre una variable predictora y una variable de respuesta.
- Siempre que realizamos una regresión lineal, queremos saber si existe una relación estadísticamente significativa entre la variable predictora y la variable de respuesta.
- Probamos la significancia realizando una prueba t para la pendiente de regresión.

Regresión lineal simple

- Usamos la siguiente hipótesis nula y alternativa para esta prueba t:
 - $H_0: \beta_1 = 0$ (la pendiente es igual a cero)
 - $H_A: \beta_1 \neq 0$ (la pendiente no es igual a cero)
- Luego calculamos el estadístico de prueba $t = b / SE_b$
- Con b : estimación del coeficiente de la variable predictora y SE_b : error estándar de la estimación del coeficiente.
- Si el valor-p que corresponde a t es menor que algún umbral (por ejemplo, $\alpha = .05$), entonces rechazamos la H_0 y concluimos que existe una relación estadísticamente significativa entre la variable predictora y la variable de respuesta.

Regresión lineal simple

Ejemplo

- Supongamos que un profesor quiere analizar la relación entre las horas estudiadas y la calificación del examen de 40 de sus alumnos.
- Realiza una regresión lineal simple usando las horas estudiadas como la variable de predicción y la puntuación del examen recibido como la variable de respuesta.
- La siguiente tabla muestra los resultados del modelo de regresión:

	Coefficients	Standard Error	t Stat	p-value
Intercept	66.99	6.211	10.785	<0.000
Hours	1.117	1.025	1.089	0.283

Regresión lineal simple

Ejemplo

	Coefficients	Standard Error	t Stat	p-value
Intercept	66.99	6.211	10.785	<0.000
Hours	1.117	1.025	1.089	0.283

- Para determinar si las horas estudiadas tienen una relación estadísticamente significativa con la calificación del examen final, podemos realizar una prueba t.
- Usamos la siguiente hipótesis nula y alternativa para esta prueba t:
 - $H_0: \beta_1 = 0$ (la pendiente para las horas estudiadas es igual a cero)
 - $H_A: \beta_1 \neq 0$ (la pendiente para las horas estudiadas no es igual a cero)
- Luego calculamos el estadístico de prueba de la siguiente manera:
$$t = \text{coeficiente} / SE_{\text{coeficiente}} = 1.117 / 1.025 = 1.089$$
- El valor p que corresponde a $t = 1.089$ con $df = n-2 = 40-2 = 38$ es 0.283.

Regresión lineal simple

Ejemplo

	Coefficients	Standard Error	t Stat	p-value
Intercept	66.99	6.211	10.785	<0.000
Hours	1.117	1.025	1.089	0.283

- Usamos la siguiente hipótesis nula y alternativa para esta prueba t:
 - $H_0: \beta_1 = 0$ (la pendiente para las horas estudiadas es igual a cero)
 - $H_A: \beta_1 \neq 0$ (la pendiente para las horas estudiadas no es igual a cero)
- Dado que este valor-p no es menor que .05, no podemos rechazar la hipótesis nula.
- Esto significa que las horas estudiadas no tienen una relación estadísticamente significativa con la calificación del examen final.

Regresión lineal simple

Ejemplo


- Supongamos que tenemos el siguiente conjunto de datos con el peso y la altura de siete individuos:
- Sea el peso la variable predictora y la altura la variable respuesta.

Weight (lbs)	Height (inches)
140	60
155	62
159	67
179	70
192	71
200	72
212	75

Regresión lineal simple

Ejemplo

- Si graficamos estas dos variables usando un diagrama de dispersión, con el peso en el eje x y la altura en el eje y :




Weight (lbs)	Height (inches)
140	60
155	62
159	67
179	70
192	71
200	72
212	75

Regresión lineal simple

Ejemplo


- Del diagrama de dispersión podemos ver claramente que a medida que aumenta el peso, la altura tiende a aumentar también.
- Pero para cuantificar realmente esta relación entre el peso y la altura, necesitamos usar la regresión lineal.



Regresión lineal simple

Ejemplo

- Usando la regresión lineal, podemos encontrar la línea que mejor “se ajusta” a nuestros datos.
- Esta línea se conoce como la línea de regresión de mínimos cuadrados y se puede usar para ayudarnos a comprender las relaciones entre el peso y la altura.



Regresión lineal simple

Ejemplo



- Buscamos la línea de regresión de mínimos cuadrados:

$$\hat{y} = b_0 + b_1 x$$

- Encontramos:

$$\hat{y} = 32.7830 + 0.2001 x$$


- Si agregamos esta línea al gráfico, así es como se vería:



Regresión lineal simple

Ejemplo


- $b_0 = 32.7830$.
- Esto significa que cuando x es cero libras, la altura pronosticada es de 32.7830 pulgadas.
- A veces, el valor de b_0 puede ser útil, pero en este ejemplo específico, en realidad no tiene sentido interpretar b_0 ya que una persona no puede pesar cero libras.



Regresión lineal simple

Ejemplo


- Por otro lado, $b_1 = 0.2001$.
- Esto significa que un aumento de una unidad en x está asociado con un aumento de 0.2001 unidades en y .
- En este caso, un aumento de peso de una libra se asocia con un aumento de altura de 0.2001 pulgadas.



Regresión lineal simple

Ejemplo


- Usando esta línea de regresión podemos responder preguntas como:
- Para una persona que pesa 170 libras, ¿qué altura esperaríamos que midiera?
- Para responder, simplemente se introduce 170 en nuestra línea de regresión para x:
$$\hat{y} = 32.7830 + 0.2001 (170) = 66.8 \text{ pulgadas}$$



Regresión lineal simple

Ejemplo

- Precaución: cuando use una ecuación de regresión, asegúrese de usar solo valores para x que estén dentro del rango del conjunto de datos original usados para generar la línea de regresión.
- Los pesos de este conjunto de datos oscilaron entre 140 y 212 libras. Solo tiene sentido responder preguntas sobre la altura prevista cuando el peso está entre 140 y 212 libras.



Regresión lineal simple

Coeficiente de determinación R^2

- Una forma de medir qué tan bien "se ajusta" la línea de regresión a los datos es usar el coeficiente de determinación, indicado como R^2 .
- R^2 es la proporción de la varianza en la variable de respuesta que puede ser explicada por la variable predictora. Oscila entre 0 y 1.
- Un valor de 0 indica que la variable de respuesta no puede explicarse en absoluto por la variable de predicción. Un valor de 1 indica que la variable de respuesta puede ser perfectamente explicada sin error por la variable predictora.

Regresión lineal simple

Coeficiente de determinación R^2

- Por ejemplo, un R^2 de 0.2 indica que la variable predictora puede explicar el 20% de la varianza en la variable de respuesta; un R^2 de 0.77 indica que el 77% de la varianza en la variable respuesta puede ser explicada por la variable predictora.
- En el ejemplo del peso y la altura, se obtuvo un R^2 de 0.9311, lo que indica que el 93.11 % de la variabilidad en la altura puede explicarse por la variable peso.
- Esto nos dice que el peso es un muy buen predictor de la altura.
- En Regresión lineal simple, R^2 es el cuadrado del coeficiente de correlación R .

Supuestos de la regresión lineal simple

- Para que los resultados de un modelo de regresión lineal sean válidos y confiables, debemos verificar que se cumplan los siguientes supuestos:
 1. Relación lineal: existe una relación lineal entre la variable independiente x , y la variable dependiente y .
 2. Independencia: Los residuales son independientes. En particular, no hay correlación entre residuales consecutivos.

Supuestos de la regresión lineal simple

- 3. Homocedasticidad: Los residuales tienen varianza constante en todos los niveles de x .
- 4. Normalidad: Los residuales del modelo se distribuyen normalmente.
- Si se viola una o más de estos supuestos, entonces los resultados de nuestra regresión lineal pueden ser poco confiables o incluso engañosos.
- También hay que estudiar con detenimiento los valores atípicos (extremos) e influyentes, ya que pueden generar una falsa correlación que realmente no existe, u ocultar una existente.

Supuestos de la regresión lineal simple


Relación lineal

- El primer supuesto es que existe una relación lineal entre la variable independiente, x , y la variable dependiente, y .
- La forma más sencilla de detectar si se cumple esta suposición es crear un diagrama de dispersión de x frente a y .
- Si parece que los puntos en la gráfica podrían caer a lo largo de una línea recta, entonces existe algún tipo de relación lineal entre las dos variables y se cumple esta suposición.

Supuestos de la regresión lineal simple

Relación lineal


- Por ejemplo, los puntos en el gráfico parecen caer aproximadamente en una línea recta, lo que indica que existe una relación lineal entre x e y :



Supuestos de la regresión lineal simple

Relación lineal


- Sin embargo, no parece haber una relación lineal entre x e y en el siguiente gráfico:



Supuestos de la regresión lineal simple

Relación lineal

- Y en este gráfico parece haber una relación clara entre x e y , pero no una relación lineal:



Supuestos de la regresión lineal simple

Relación lineal

- Si el diagrama de dispersión para x e y no muestra una relación lineal entre las dos variables, entonces puede:
- Aplicar una transformación no lineal a la variable independiente y/o dependiente. Los ejemplos comunes incluyen tomar el logaritmo, la raíz cuadrada o el recíproco de la variable independiente y/o dependiente.
- Agregar otra variable independiente al modelo. Por ejemplo, si la gráfica de x frente a y tiene una forma parabólica, podría tener sentido agregar x^2 como una variable independiente adicional en el modelo.

Supuestos de la regresión lineal simple

Independencia

- La siguiente suposición de la regresión lineal es que los residuos son independientes.
- Esto es principalmente relevante cuando se trabaja con datos de series temporales.
- Idealmente, no queremos que haya un patrón entre residuos consecutivos. Por ejemplo, los residuos no deberían crecer constantemente a medida que pasa el tiempo.

Supuestos de la regresión lineal simple

Independencia

- Una forma de probar si se cumple esta suposición es observar una gráfica de serie de tiempo de los residuales (gráfica de residuales frente al tiempo).
- Idealmente, la mayoría de las autocorrelaciones residuales deben estar dentro de las bandas de confianza del 95 % alrededor de cero, que se ubican aproximadamente en ± 2 sobre la raíz cuadrada de n , donde n es el tamaño de la muestra.
- También puede probar formalmente si se cumple esta suposición mediante la prueba de Durbin-Watson.

Supuestos de la regresión lineal simple

Homocedasticidad

- La siguiente suposición de la regresión lineal es que los residuales tienen una varianza constante en todos los niveles de x , u homocedasticidad.
- En el caso contrario, heteroscedasticidad de los residuales, los resultados del análisis se vuelven difíciles de confiar.
- Específicamente, la heterocedasticidad aumenta la varianza de las estimaciones del coeficiente de regresión, pero el modelo de regresión no se da cuenta de esto.

Supuestos de la regresión lineal simple


Homocedasticidad

- Esto hace que sea mucho más probable que un modelo de regresión declare que un término es estadísticamente significativo, cuando en realidad no lo es.
- La forma más sencilla de detectar la heteroscedasticidad es mediante la creación de una gráfica de valor ajustado vs residual.
- Una vez que ajusta una línea de regresión a un conjunto de datos, se puede crear un diagrama de dispersión que muestre los valores ajustados del modelo frente a los residuos de esos valores ajustados.

Supuestos de la regresión lineal simple

Homocedasticidad

- El siguiente gráfico de dispersión muestra un valor ajustado típico frente a un gráfico residual en el que hay heteroscedasticidad.
- Los residuales se vuelven mucho más dispersos a medida que los valores ajustados se hacen más grandes, en forma de “cono”.



Supuestos de la regresión lineal simple

Homocedasticidad

- Hay tres formas comunes de corregir la heteroscedasticidad:

1. Transformar la variable dependiente.

- Una transformación común es simplemente tomar el logaritmo de la variable dependiente.
- Por ejemplo, si usamos el tamaño de la población (variable independiente) para predecir el número de florerías en una ciudad (variable dependiente), podemos intentar usar el tamaño de la población para predecir el logaritmo del número de florerías en una ciudad.

Supuestos de la regresión lineal simple

Homocedasticidad

2. Redefinir la variable dependiente.

- Una forma común es usar una tasa, en lugar del valor bruto.
- Por ejemplo, en lugar de usar el tamaño de la población para predecir la cantidad de florerías en una ciudad, podemos usar el tamaño de la población para predecir la cantidad de florerías per cápita.
- En la mayoría de los casos, esto reduce la variabilidad que ocurre naturalmente entre poblaciones más grandes, ya que estamos midiendo la cantidad de tiendas de flores por persona, en lugar de la cantidad total de tiendas de flores.

Supuestos de la regresión lineal simple

Homocedasticidad

3. Utilizar regresión ponderada.

- Este tipo de regresión asigna un peso a cada punto de datos en función de la varianza de su valor ajustado.
- Esencialmente, esto otorga pesos pequeños a los puntos de datos que tienen varianzas más altas, lo que reduce sus residuos al cuadrado.
- Cuando se utilizan los pesos adecuados, esto puede eliminar el problema de la heterocedasticidad.

Supuestos de la regresión lineal simple


Normalidad

- La siguiente suposición es que los residuos se distribuyen normalmente.
- Hay dos formas comunes de verificar si se cumple esta suposición:
 1. Verifique la suposición visualmente usando diagramas Q-Q.
- Una gráfica Q-Q (cuantil-cuantil), es un tipo de gráfica que podemos usar para determinar si los residuos de un modelo siguen o no una distribución normal.
- Si los puntos en el gráfico forman aproximadamente una línea diagonal recta, entonces se cumple la suposición de normalidad.

Supuestos de la regresión lineal simple

Normalidad


- La siguiente gráfica Q-Q muestra un ejemplo de residuos que siguen aproximadamente una distribución normal:



Supuestos de la regresión lineal simple

Normalidad

- Sin embargo, el gráfico Q-Q a continuación muestra un ejemplo de cuando los residuos se apartan claramente de una línea diagonal recta, lo que indica que no siguen una distribución normal:



Supuestos de la regresión lineal simple

Normalidad

2. También puede verificar la suposición de normalidad utilizando pruebas estadísticas formales como Shapiro-Wilk, Kolmogorov-Smirnov, Jarque-Barre o D'Agostino-Pearson.
- Sin embargo, tenga en cuenta que estas pruebas son sensibles a muestras de gran tamaño, es decir, podrían concluir que los residuales no son normales cuando el tamaño de su muestra es grande.
 - Por esta razón a menudo se complementan con métodos gráficos como un diagrama Q-Q.

Supuestos de la regresión lineal simple

Normalidad

- Si se viola el supuesto de normalidad, se tienen algunas opciones:
- Primero, verificar que los valores atípicos no tengan un gran impacto en la distribución. Si hay valores atípicos presentes, asegúrese de que sean valores reales y que no sean errores de entrada de datos.
- A continuación, puede aplicar una transformación no lineal a la variable independiente y/o dependiente. Los ejemplos comunes incluyen tomar el logaritmo, la raíz cuadrada o el recíproco de la variable independiente y/o dependiente.

Regresión lineal múltiple

- Cuando queremos comprender la relación entre una sola variable predictora y una variable de respuesta, usamos la regresión lineal simple.
- Sin embargo, si quisiéramos comprender la relación entre múltiples variables predictoras y una variable de respuesta, entonces podemos usar la regresión lineal múltiple.

Regresión lineal múltiple

- Si tenemos p variables predictoras, entonces un modelo de regresión lineal múltiple toma la forma:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

Con Y : La variable de respuesta

X_j : La j -ésima variable predictora

β_j : El efecto promedio en Y al aumentar X_j en una unidad, manteniendo fijos todos los otros predictores

ε : El error aleatorio

Regresión lineal múltiple

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

- Los valores de $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ se eligen utilizando el método de los mínimos cuadrados, que minimiza la suma de los residuos cuadrados (RSS):

$$RSS = \sum (y_i - \hat{y}_i)^2$$

Donde:

y_i : Es el valor de respuesta real para la i -ésima observación

$\hat{y}_i$: Es el valor de respuesta pronosticado basado en el modelo de regresión lineal múltiple

Cómo interpretar los resultados

- La prueba F de significancia general en la regresión es una prueba de si el modelo de regresión lineal proporciona o no un mejor ajuste a un conjunto de datos que un modelo sin variables de predicción.
- La prueba F tiene las siguientes dos hipótesis:
- Hipótesis nula (H_0): el modelo sin variables predictoras (o modelo de solo intercepción) se ajusta a los datos tan bien como su modelo de regresión.
- Hipótesis alternativa (H_A): el modelo de regresión se ajusta mejor a los datos que el modelo de solo intercepción.

Cómo interpretar los resultados

- Cuando se ajusta un modelo de regresión a un conjunto de datos, se obtiene una tabla de regresión como salida, que indica el estadístico F junto con el valor- p correspondiente para ese estadístico F .
- Si el valor- p es menor que el nivel de significación que se ha elegido (las opciones comunes son 0.01, 0.05 y 0.10), entonces se tienen pruebas suficientes para concluir que el modelo de regresión se ajusta mejor a los datos que el modelo de solo intercepción.

Regresión lineal múltiple

Ejemplo

- Supongamos que tenemos el siguiente conjunto de datos que muestra el número total de horas estudiadas, el total de exámenes preparatorios realizados y la puntuación del examen final recibida por 12 estudiantes diferentes:

	Study Hours	Prep Exams	Final Exam Score
Student 1	3	2	76
Student 2	7	6	88
Student 3	16	5	96
Student 4	14	2	90
Student 5	12	7	98
Student 6	7	4	80
Student 7	4	4	86
Student 8	19	2	89
Student 9	4	8	68
Student 10	8	4	75
Student 11	8	1	72
Student 12	3	3	76

Regresión lineal múltiple

Ejemplo

- Para analizar la relación entre las horas estudiadas y los exámenes preparatorios tomados con el puntaje del examen final por estudiante, ejecutamos una regresión lineal múltiple utilizando las horas estudiadas y los exámenes preparatorios tomados como variables predictoras y el puntaje del examen final como variable de respuesta.

	Study Hours	Prep Exams	Final Exam Score
Student 1	3	2	76
Student 2	7	6	88
Student 3	16	5	96
Student 4	14	2	90
Student 5	12	7	98
Student 6	7	4	80
Student 7	4	4	86
Student 8	19	2	89
Student 9	4	8	68
Student 10	8	4	75
Student 11	8	1	72
Student 12	3	3	76

Regresión lineal múltiple

Ejemplo

- Se obtiene la siguiente respuesta:

Regression Statistics		ANOVA					
Multiple R	0.728550902						
R Square	0.530786416						
Adjusted R Square	0.426516731						
Standard Error	7.326766656						
Observations	12						
			df	SS	MS	F	Significance F
		Regression	2	546.53308	273.2665	5.090515	0.033202256
		Residual	9	483.1335867	53.68151		
		Total	11	1029.666667			

	Coefficients	Standard Error	t Stat	P-value	Lower 95%	Upper 95%
Intercept	66.99010508	6.211445265	10.78495	1.9E-06	52.93883968	81.04137
Study Hours	1.299900324	0.417012868	3.117171	0.012375	0.356551677	2.243249
Prep Exams	1.117275106	1.025145307	1.08987	0.30409	-1.201764693	3.4363149

Regresión lineal múltiple

Ejemplo

- El estadístico $F = 5.090515$, y el valor p de ese estadístico F (*Significance F*) = 0.0332.

ANOVA

	<i>df</i>	<i>SS</i>	<i>MS</i>	<i>F</i>	<i>Significance F</i>
Regression	2	546.53308	273.2665	5.090515	0.033202256
Residual	9	483.1335867	53.68151		
Total	11	1029.666667			

- Supongamos que ya elegimos .05 como nuestro nivel de significancia.
- Dado que el valor p es menor que 0.05, podemos concluir que el modelo de regresión se ajusta mejor a los datos que el modelo de solo intercepción.
- En el contexto específico, significa que usar Horas de estudio y Exámenes de preparación permite ajustar los datos mejor que si los omitiéramos.

Regresión lineal múltiple

Ejemplo

- *Significancia F*: Es el valor p asociado con el estadístico F general.

ANOVA

	<i>df</i>	<i>SS</i>	<i>MS</i>	<i>F</i>	<i>Significance F</i>
Regression	2	546.53308	273.2665	5.090515	0.033202256
Residual	9	483.1335867	53.68151		
Total	11	1029.666667			

- Nos dice si el modelo de regresión en su conjunto es estadísticamente significativo.
- Es decir, si las dos variables predictoras combinadas tienen una asociación estadísticamente significativa con la variable de respuesta.
- En este caso, horas y exámenes preparatorios combinados sí tienen una asociación estadísticamente significativa con el puntaje del examen.

Regresión lineal múltiple

Ejemplo

	<i>Coefficients</i>	<i>Standard Error</i>	<i>t Stat</i>	<i>P-value</i>	<i>Lower 95%</i>	<i>Upper 95%</i>
Intercept	66.99010508	6.211445265	10.78495	1.9E-06	52.93883968	81.04137
Study Hours	1.299900324	0.417012868	3.117171	0.012375	0.356551677	2.243249
Prep Exams	1.117275106	1.025145307	1.08987	0.30409	-1.201764693	3.4363149

- Los coeficientes permiten formar un modelo de regresión lineal múltiple estimado:
Puntuación del examen = $66.99 + 1.29 \cdot (\text{horas}) + 1.11 \cdot (\text{exámenes})$.
- Cada unidad adicional en las horas está asociada con un aumento promedio de 1.29 puntos en el examen final, suponiendo que los exámenes de preparación se mantienen constantes.
- Cada unidad adicional en los exámenes de preparación se asocia con 1.11 puntos en el examen final, suponiendo que las horas estudiadas se mantienen constantes.

Regresión lineal múltiple

Ejemplo

	<i>Coefficients</i>	<i>Standard Error</i>	<i>t Stat</i>	<i>P-value</i>	<i>Lower 95%</i>	<i>Upper 95%</i>
Intercept	66.99010508	6.211445265	10.78495	1.9E-06	52.93883968	81.04137
Study Hours	1.299900324	0.417012868	3.117171	0.012375	0.356551677	2.243249
Prep Exams	1.117275106	1.025145307	1.08987	0.30409	-1.201764693	3.4363149

- Podemos usar el modelo para encontrar el puntaje esperado que recibirá un estudiante en función del total de horas y los exámenes de preparación realizados.
- Por ejemplo, se espera que un estudiante que estudia durante 4 horas y toma 1 examen de preparación obtenga 73.26 en el examen:
- Puntuación del examen = $66.99 + 1.29*(4) + 1.11*(1) = 73.26$

Regresión lineal múltiple

Ejemplo

	<i>Coefficients</i>	<i>Standard Error</i>	<i>t Stat</i>	<i>P-value</i>	<i>Lower 95%</i>	<i>Upper 95%</i>
Intercept	66.99010508	6.211445265	10.78495	1.9E-06	52.93883968	81.04137
Study Hours	1.299900324	0.417012868	3.117171	0.012375	0.356551677	2.243249
Prep Exams	1.117275106	1.025145307	1.08987	0.30409	-1.201764693	3.4363149

- Ahora bien. los valores p individuales nos dicen si cada variable predictiva es estadísticamente significativa o no.
- Podemos ver que las horas son estadísticamente significativas ($p = 0.01$) en $\alpha = 0.05$, mientras que los exámenes de preparación tomados no ($p = 0.30$).

Regresión lineal múltiple

Ejemplo

	<i>Coefficients</i>	<i>Standard Error</i>	<i>t Stat</i>	<i>P-value</i>	<i>Lower 95%</i>	<i>Upper 95%</i>
Intercept	66.99010508	6.211445265	10.78495	1.9E-06	52.93883968	81.04137
Study Hours	1.299900324	0.417012868	3.117171	0.012375	0.356551677	2.243249
Prep Exams	1.117275106	1.025145307	1.08987	0.30409	-1.201764693	3.4363149

- Dado que los exámenes de preparación realizados no son estadísticamente significativos, es posible que decidamos eliminarlos del modelo final.
- Esto porque, aunque el coeficiente de exámenes indica que las puntuaciones de los estudiantes que realizaron exámenes de preparación sí fueron superiores, esta diferencia podría atribuirse a casualidad aleatoria.

Regresión lineal múltiple

Ejemplo

- R-Cuadrado: El coeficiente de determinación.
- Es la proporción de la varianza en la variable de respuesta que puede ser explicada por las variables predictoras.
- En el ejemplo, el 53.0 % de la variación en los puntajes de los exámenes puede explicarse por la cantidad de horas estudiadas y la cantidad de exámenes preparatorios realizados.

<i>Regression Statistics</i>	
Multiple R	0.728550902
R Square	0.530786416
Adjusted R Square	0.426516731
Standard Error	7.326766656
Observations	12

Regresión lineal múltiple

Ejemplo

- El valor de R-cuadrado puede oscilar entre 0 y 1.
- Un valor de 0 indica que la variable predictora no puede explicar la variable de respuesta en absoluto.
- Un valor de 1 indica que la variable de respuesta puede ser perfectamente explicada sin error por la variable predictora.
- Cuanto mayor sea el R-cuadrado de un modelo, mejor será el modelo capaz de ajustar los datos.

<i>Regression Statistics</i>	
Multiple R	0.728550902
R Square	0.530786416
Adjusted R Square	0.426516731
Standard Error	7.326766656
Observations	12

Regresión lineal múltiple

Ejemplo

- Error estándar: es la distancia promedio que los valores observados caen desde la línea de regresión.
- En el ejemplo, caen un promedio de 7.326 unidades desde la línea de regresión.
- Cuanto menor sea el error estándar, mejor podrá un modelo ajustar los datos.

<i>Regression Statistics</i>	
Multiple R	0.728550902
R Square	0.530786416
Adjusted R Square	0.426516731
Standard Error	7.326766656
Observations	12

Cómo interpretar los resultados

- Cuando se ajusta un modelo de regresión a un conjunto de datos, se obtiene una tabla de regresión como salida, que indica el estadístico F junto con el valor- p correspondiente para ese estadístico F .
- Si el valor- p es menor que el nivel de significación que ha elegido (las opciones comunes son 0.01, 0.05 y 0.10), entonces tiene pruebas suficientes para concluir que su modelo de regresión se ajusta mejor a los datos que el modelo de solo intercepción.

Supuestos de la regresión lineal múltiple

- Al igual que con la regresión lineal simple, para la regresión lineal múltiple se debe asegurar de que se cumplan los supuestos.
- En regresión lineal múltiple, además de los supuestos ya estudiados para regresión lineal simple (relación lineal, independencia, homocedasticidad y normalidad de los residuales), se debe verificar la multicolinealidad, es decir, que ninguna de las variables predictoras esté altamente correlacionada con las otras variables predictoras.

Supuestos de la regresión lineal múltiple

No multicolinealidad

- La regresión lineal múltiple asume que ninguna de las variables predictoras está altamente correlacionada con las otras.
- Si se da el caso de que sí están altamente correlacionadas (multicolinealidad), las estimaciones de los coeficientes del modelo se vuelvan poco confiables.
- Esto es un problema dado que, si dos o más variables predictoras están altamente correlacionadas entre sí, no brindan información única o independiente en el modelo de regresión, por lo que el modelo será difícil de interpretar.

Supuestos de la regresión lineal múltiple

No multicolinealidad

- La forma más fácil de determinar si se cumple este supuesto es calcular el valor VIF (factor de inflación de la varianza) para cada variable predictora.
- Los valores VIF comienzan en 1 y no tienen límite superior. Como regla general:
 - Un valor de 1 indica que no hay correlación entre una variable predictora dada y cualquier otra variable predictora en el modelo.
 - Un valor entre 1 y 5 indica una correlación moderada entre una variable predictora dada y otras variables predictoras en el modelo, pero no es lo suficientemente grave como para requerir atención.

Supuestos de la regresión lineal múltiple

No multicolinealidad

- Un valor VIF superior a 5 indica una correlación potencialmente severa entre una variable predictora dada y otras variables predictoras en el modelo. En este caso, las estimaciones de los coeficientes y los valores p en el resultado de la regresión probablemente no sean confiables.

Supuestos de la regresión lineal múltiple

No multicolinealidad

- Por ejemplo, supongamos que ejecutamos un análisis de regresión usando las variables predictoras altura, talla de calzado y horas dedicadas a practicar por día para predecir el salto vertical máximo de los jugadores de baloncesto y obtenemos el siguiente resultado:

	<i>Coefficients</i>	<i>Standard Error</i>	<i>t Stat</i>	<i>P-value</i>	<i>VIF</i>
Intercept	-15.26179784	3.612395656	-4.2248	0.002897	
height	4.32876917	0.926682091	4.6713	0.001600	12.33
shoe size	-0.67498267	0.176166878	-3.8315	0.005007	22.34
practice hours per day	0.72611633	0.087247634	8.3225	0.000004	1.08

Supuestos de la regresión lineal múltiple

No multicolinealidad

	<i>Coefficients</i>	<i>Standard Error</i>	<i>t Stat</i>	<i>P-value</i>	<i>VIF</i>
Intercept	-15.26179784	3.612395656	-4.2248	0.002897	
height	4.32876917	0.926682091	4.6713	0.001600	12.33
shoe size	-0.67498267	0.176166878	-3.8315	0.005007	22.34
practice hours per day	0.72611633	0.087247634	8.3225	0.000004	1.08

- Los valores de VIF para altura y tamaño del zapato son mayores que 5.
- Esto indica que es probable que sufran de multicolinealidad y que las estimaciones de sus coeficientes y los valores-p no sean confiables.
- El modelo nos dice que, por cada aumento de una unidad en el tamaño del zapato, el salto vertical se reduce en 0.67498 pulgadas, suponiendo que la altura y las horas de práctica se mantienen constantes, lo que no parece tener sentido.

Supuestos de la regresión lineal múltiple

No multicolinealidad

- Si una o más de las variables predictoras tiene un valor de VIF superior a 5, la forma más fácil de resolver este problema es simplemente eliminar las variables predictoras con los valores altos de VIF.
- Como alternativa, si desea mantener cada variable predictora en el modelo, puede usar un método estadístico diferente, como la regresión de cresta, la regresión de lazo o la regresión de mínimos cuadrados parciales, que están diseñadas para manejar variables predictoras que están altamente correlacionadas.

Regresión lineal múltiple en R

Ejemplo

- Para este otro ejemplo, usaremos el conjunto de datos mtcars de R, que contiene información sobre varios atributos para 32 autos diferentes:

```
head(mtcars)
```

#	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
#Mazda RX4	21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
#Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
#Datsun 710	22.8	4	108	93	3.85	2.320	18.61	1	1	4	1
#Hornet 4 Drive	21.4	6	258	110	3.08	3.215	19.44	1	0	3	1
#Hornet Sportabout	18.7	8	360	175	3.15	3.440	17.02	0	0	3	2
#Valiant	18.1	6	225	105	2.76	3.460	20.22	1	0	3	1

Regresión lineal múltiple en R

Ejemplo

- Construiremos un modelo de regresión lineal múltiple que usa mpg como variable de respuesta y disp (cilindrada, en pulgadas cúbicas), hp (potencia bruta) y drat (relación de eje trasero) como variables predictoras.

```
data <- mtcars[ , c("mpg", "disp", "hp", "drat")]
```

- Antes de ajustar el modelo, podemos examinar los datos para comprenderlos mejor y evaluar visualmente si la regresión lineal múltiple sería un buen modelo para ajustarse a estos datos.

Regresión lineal múltiple en R


Ejemplo

- En particular, debemos verificar si las variables predictoras tienen una asociación lineal con la variable de respuesta.
- Para hacerlo, podemos usar la función `pairs()` para crear un diagrama de dispersión de cada posible par de variables:

```
pairs(data, pch = 18, col = "steelblue")
```

Regresión lineal múltiple en R

Ejemplo



```
pairs(data, pch = 18, col = "steelblue")
```

De la gráfica:

- mpg y disp parecen tener una fuerte correlación lineal negativa
- mpg y hp parecen tener una fuerte correlación lineal negativa
- mpg y drat parecen tener una modesta correlación lineal positiva

Regresión lineal múltiple en R

Ejemplo


- También podríamos usar la función `ggpairs()` de la biblioteca `GGally` para crear un gráfico similar que contenga los coeficientes de correlación lineal reales para cada par de variables:

```
#install and load the GGally library
install.packages("GGally")
library(GGally)

#generate the pairs plot
ggpairs(data)
```

Regresión lineal múltiple en R

Ejemplo



- Cada una de las variables predictoras parece tener una correlación lineal notable con la variable de respuesta mpg, por lo que procederemos a ajustar el modelo de regresión lineal a los datos.

Regresión lineal múltiple en R

Ajuste del modelo

- La sintaxis básica para ajustar un modelo de regresión lineal múltiple en R es:

```
lm(response_variable ~ predictor_variable1 + predictor_variable2 + ..., data = data)
```

- En este caso:

```
model <- lm(mpg ~ disp + hp + drat, data = data)
```

Ejemplo - Regresión lineal múltiple en R


Revisión de supuestos

La distribución de los residuales del modelo debe ser aproximadamente normal.

- Podemos crear un histograma de residuales:

```
hist(residuals(model), col = "steelblue")
```

- Aunque la distribución está ligeramente sesgada hacia la derecha, no es lo suficientemente anormal como para causar grandes preocupaciones.




Ejemplo - Regresión lineal múltiple en R

Revisión de supuestos

La varianza de los residuales debe ser consistente.

- Podemos crear un gráfico de valor ajustado vs residual:


```
#create fitted value vs residual plot  
plot(fitted(model), residuals(model))  
  
#add horizontal line at 0  
abline(h = 0, lty = 2)
```



Ejemplo - Regresión lineal múltiple en R

Revisión de supuestos

- Idealmente, los residuos estarían igualmente dispersos en cada valor ajustado.
- Podemos ver en la gráfica que la dispersión tiende a ser un poco más grande para valores ajustados más grandes, pero este patrón no es lo suficientemente extremo como para causar demasiada preocupación.



Ejemplo - Regresión lineal múltiple en R

Interpretación de la salida del modelo

- Una vez verificados los supuestos, podemos ver el resultado del modelo:

```
summary(model)

#Call:
#lm(formula = mpg ~ disp + hp + drat, data = data)
#
#Residuals:
#    Min       1Q   Median       3Q      Max
#-5.1225 -1.8454 -0.4456  1.1342  6.4958
```

```
#Coefficients:
#              Estimate Std. Error t value Pr(>|t|)
#(Intercept) 19.344293   6.370882   3.036  0.00513 **
#disp        -0.019232   0.009371  -2.052  0.04960 *
#hp          -0.031229   0.013345  -2.340  0.02663 *
#drat         2.714975   1.487366   1.825  0.07863 .
#---
#Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#
#Residual standard error: 3.008 on 28 degrees of freedom
#Multiple R-squared:  0.775,    Adjusted R-squared:  0.7509
#F-statistic: 32.15 on 3 and 28 DF,  p-value: 3.28e-09
```

Ejemplo - Regresión lineal múltiple en R

Interpretación de la salida del modelo

- El estadístico F general es 32.15 y el valor p correspondiente es 3.28e-09.
- Esto indica que el modelo general es estadísticamente significativo.
- En otras palabras, el modelo de regresión como un todo es útil.

#Coefficients:

#	Estimate	Std. Error	t value	Pr(> t)	
#(Intercept)	19.344293	6.370882	3.036	0.00513	**
#disp	-0.019232	0.009371	-2.052	0.04960	*
#hp	-0.031229	0.013345	-2.340	0.02663	*
#drat	2.714975	1.487366	1.825	0.07863	.

#---
#Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

#Residual standard error: 3.008 on 28 degrees of freedom
#Multiple R-squared: 0.775, Adjusted R-squared: 0.7509
#F-statistic: 32.15 on 3 and 28 DF, p-value: 3.28e-09

Ejemplo - Regresión lineal múltiple en R

Interpretación de la salida del modelo

- *disp* es estadísticamente significativo al nivel de significación de 0.05.
- En particular, el coeficiente indica que un aumento de una unidad en *disp* está asociado con una disminución de 0.019 unidades, en promedio, en *mpg*, suponiendo que *hp* y *drat* se mantengan constantes.

```
#Coefficients:
#             Estimate Std. Error t value Pr(>|t|)
#(Intercept) 19.344293   6.370882   3.036  0.00513 **
#disp        -0.019232   0.009371  -2.052  0.04960 *
#hp          -0.031229   0.013345  -2.340  0.02663 *
#drat         2.714975   1.487366   1.825  0.07863 .
#---
#Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#
#Residual standard error: 3.008 on 28 degrees of freedom
#Multiple R-squared:  0.775,    Adjusted R-squared:  0.7509
#F-statistic: 32.15 on 3 and 28 DF,  p-value: 3.28e-09
```

Ejemplo - Regresión lineal múltiple en R

Interpretación de la salida del modelo

- *hp* es estadísticamente significativo al nivel de significación de 0.05.
- En particular, el coeficiente de salida indica que un aumento de una unidad en *hp* está asociado con una disminución de 0.031 unidades, en promedio, en *mpg*, suponiendo que *disp* y *drat* se mantengan constantes.

```
#Coefficients:
#           Estimate Std. Error t value Pr(>|t|)
#(Intercept) 19.344293    6.370882   3.036  0.00513 **
#disp        -0.019232    0.009371  -2.052  0.04960 *
#hp          -0.031229    0.013345  -2.340  0.02663 *
#drat         2.714975    1.487366   1.825  0.07863 .
#---
#Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#
#Residual standard error: 3.008 on 28 degrees of freedom
#Multiple R-squared:  0.775,    Adjusted R-squared:  0.7509
#F-statistic: 32.15 on 3 and 28 DF,  p-value: 3.28e-09
```

Ejemplo - Regresión lineal múltiple en R

Interpretación de la salida del modelo

- *drat* es estadísticamente significativo en el nivel de significación de 0.10.
- En particular, el coeficiente de salida indica que un aumento de una unidad en *drat* está asociado con un aumento de 2.715 unidades, en promedio, en *mpg*, suponiendo que *disp* y *hp* se mantengan constantes.

```
#Coefficients:
#             Estimate Std. Error t value Pr(>|t|)
#(Intercept) 19.344293   6.370882   3.036  0.00513 **
#disp        -0.019232   0.009371  -2.052  0.04960 *
#hp          -0.031229   0.013345  -2.340  0.02663 *
#drat         2.714975   1.487366   1.825  0.07863 .
#---
#Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#
#Residual standard error: 3.008 on 28 degrees of freedom
#Multiple R-squared:  0.775,    Adjusted R-squared:  0.7509
#F-statistic: 32.15 on 3 and 28 DF,  p-value: 3.28e-09
```

Ejemplo - Regresión lineal múltiple en R

Evaluación de la bondad de ajuste del modelo

```
#Residual standard error: 3.008 on 28 degrees of freedom  
#Multiple R-squared:  0.775,    Adjusted R-squared:  0.7509  
#F-statistic: 32.15 on 3 and 28 DF,  p-value: 3.28e-09
```

- Para evaluar qué tan "bien" se ajusta el modelo de regresión a los datos, podemos observar las métricas *Multiple R-squared* y *Residual standard error*.
- *Multiple R-Squared* mide la fuerza de la relación lineal entre las variables predictoras y la variable de respuesta.
- Un valor de 1 indica una relación lineal perfecta, mientras que un valor de 0 indica que no existe ninguna relación lineal.

Ejemplo - Regresión lineal múltiple en R

Evaluación de la bondad de ajuste del modelo

```
#Residual standard error: 3.008 on 28 degrees of freedom  
#Multiple R-squared:  0.775,    Adjusted R-squared:  0.7509  
#F-statistic: 32.15 on 3 and 28 DF,  p-value: 3.28e-09
```

- *Multiple R-Squared* es la proporción de la varianza en la variable de respuesta que puede ser explicada por las variables predictoras.
- *Adjusted R-Squared* es una versión ajustada que penaliza el número de predictores del modelo. Esto evita que el R^2 aumente simplemente porque se añadieron variables, y se ajusta en función del tamaño de la muestra y el número de predictores.
- En este caso el Adjusted R-squared es 0.7509, por lo que los predictores del modelo pueden explicar el 75.09 % de la variación en *mpg*.

Ejemplo - Regresión lineal múltiple en R

Evaluación de la bondad de ajuste del modelo

```
#Residual standard error: 3.008 on 28 degrees of freedom  
#Multiple R-squared:  0.775,    Adjusted R-squared:  0.7509  
#F-statistic: 32.15 on 3 and 28 DF,  p-value: 3.28e-09
```

- El error estándar residual mide la distancia promedio a la que caen los valores observados desde la línea de regresión.
- En este ejemplo, los valores observados caen un promedio de 3.008 unidades desde la línea de regresión.

Ejemplo - Regresión lineal múltiple en R

Usar el modelo para predicciones

- Del resultado del modelo sabemos que la ecuación de regresión lineal múltiple ajustada es la siguiente:

$$\text{mpg}_{\text{hat}} = -19.343 - 0.019 \cdot \text{disp} - 0.031 \cdot \text{hp} + 2.715 \cdot \text{drat}$$

- Podemos usar esta ecuación para hacer predicciones acerca de lo que serán las millas por galón para nuevas observaciones.
- Por ejemplo, podemos predecir el valor de *mpg* para un automóvil que tiene los siguientes atributos: *disp* = 220, *hp* = 150, *drat* = 3

Ejemplo - Regresión lineal múltiple en R

Usar el modelo para predicciones

```
#define the coefficients from the model output
intercept <- coef(summary(model))["(Intercept)", "Estimate"]
disp <- coef(summary(model))["disp", "Estimate"]
hp <- coef(summary(model))["hp", "Estimate"]
drat <- coef(summary(model))["drat", "Estimate"]

#use the model coefficients to predict the value for mpg
intercept + disp*220 + hp*150 + drat*3

#[1] 18.57373
```

- Para un carro con $\text{disp} = 220$, $\text{hp} = 150$, y $\text{drat} = 3$, el modelo predice que tendrá un mpg de 18.57373.

Ejemplo - Regresión lineal múltiple en R

Revisión de Multicolinealidad

- En el ejemplo había quedado pendiente la revisión del supuesto de multicolinealidad. Usaremos la función `vif()` de la biblioteca `car` para calcular el VIF para cada variable predictora en el modelo:

```
> vif(model)
      disp      hp      drat
4.621988 2.868264 2.166843
```

- Se puede ver que el VIF más alto es para `disp`, llegando bastante cerca al valor límite de 5, lo que indicaría un problema potencial de multicolinealidad.
- Una opción sería eliminar esta variable del modelo y analizar el impacto en los valores R-cuadrado y error estándar.

Regresión lineal múltiple en R

Revisión del modelo

- Si replanteamos el modelo omitiendo la variable disp:

```
lm(formula = mpg ~ hp + drat, data = data)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	10.789861	5.077752	2.125	0.042238	*
hp	-0.051787	0.009293	-5.573	5.17e-06	***
drat	4.698158	1.191633	3.943	0.000467	***

Residual standard error: 3.17 on 29 degrees of freedom
Multiple R-squared: 0.7412, Adjusted R-squared: 0.7233
F-statistic: 41.52 on 2 and 29 DF, p-value: 3.081e-09

```
> vif(model2)
```

hp	drat
1.252167	1.252167

Regresión lineal múltiple en R

Revisión del modelo

- Finalmente, solo con disp y hp:

```
lm(formula = mpg ~ disp + hp, data = data)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	30.735904	1.331566	23.083	< 2e-16 ***
disp	-0.030346	0.007405	-4.098	0.000306 ***
hp	-0.024840	0.013385	-1.856	0.073679 .

Residual standard error: 3.127 on 29 degrees of freedom

Multiple R-squared: 0.7482, Adjusted R-squared: 0.7309

F-statistic: 43.09 on 2 and 29 DF, p-value: 2.062e-09

```
> vif(model4)
```

disp	hp
2.670938	2.670938

Regresión lineal múltiple en R

Revisión del modelo

- Ahora otro modelo solo con disp y drat:

```
lm(formula = mpg ~ disp + drat, data = data)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	21.844880	6.747971	3.237	0.00302	**
disp	-0.035694	0.006653	-5.365	9.19e-06	***
drat	1.802027	1.542091	1.169	0.25210	

Residual standard error: 3.232 on 29 degrees of freedom

Multiple R-squared: 0.731, Adjusted R-squared: 0.7125

F-statistic: 39.41 on 2 and 29 DF, p-value: 5.385e-09

```
> vif(model3)
      disp      drat 
2.017772 2.017772
```

Revisión del modelo

Variables	p-value	R ² ajustado	Error residual	Factor de inflación de la varianza (VIF)
disp, hp, drat	3.280e-09	0.7509	3.008 uds	4.621988, 2.868264, 2.166843
hp, drat	3.081e-09	0.7233	3.170 uds	1.252167, 1.252167
hp, disp	2.062e-09	0.7309	3.127 uds	2.670938, 2.670938
disp, drat	5.385e-09	0.7125	3.232 uds	2.017772, 2.017772

- En resumen, el modelo con las tres variables es el que mejor predice la variable de respuesta mpg.
- Eliminar alguna de las tres variables no mejoró la predicción.

Graficar regresión lineal múltiple

- Es fácil visualizar la línea de regresión cuando analizamos una regresión lineal simple, dado que tenemos una sola variable predictora y una variable de respuesta.
- Sin embargo, en regresión lineal múltiple, tenemos varias variables predictoras y no podemos simplemente trazar una línea de regresión en un gráfico 2-D.
- En su lugar, podemos usar gráficas de variables agregadas (a veces denominadas “gráficas de regresión parcial”), que son gráficas individuales que muestran la relación entre la variable de respuesta y una variable predictora, mientras se controla la presencia de otras variables predictoras en el modelo.

Graficar regresión lineal múltiple

- Por ejemplo, en el modelo de regresión lineal múltiple creado para *mtcars* se obtuvieron los siguientes resultados:
- El valor de p para cada uno de los coeficientes es menor que 0.1.
- Por simplicidad, supondremos que cada variable predictora es significativa y debe incluirse en el modelo:


```
#Coefficients:
#           Estimate Std. Error t value Pr(>|t|)
#(Intercept) 19.344293   6.370882   3.036  0.00513 **
#disp        -0.019232   0.009371  -2.052  0.04960 *
#hp          -0.031229   0.013345  -2.340  0.02663 *
#drat         2.714975   1.487366   1.825  0.07863 .
#---
#Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#
#Residual standard error: 3.008 on 28 degrees of freedom
#Multiple R-squared:  0.775,    Adjusted R-squared:  0.7509
#F-statistic: 32.15 on 3 and 28 DF,  p-value: 3.28e-09
```

Graficar regresión lineal múltiple

Para producir diagramas de variables agregadas, podemos usar la función `avPlots()` del paquete `car`:

```
#load car package
library(car)


#produce added variable plots
avPlots(model)
```




Graficar regresión lineal múltiple

El eje x muestra una única variable predictora y el eje y muestra la variable de respuesta.

La línea azul muestra la asociación entre la variable predictora y la variable de respuesta, manteniendo constante el valor de todas las demás variables predictoras.




Graficar regresión lineal múltiple



Graficar regresión lineal múltiple

Los puntos etiquetados representan las 2 observaciones con los residuos más grandes y las 2 observaciones con el apalancamiento parcial (*) más grande.

(*) influencia de una observación individual en la estimación del coeficiente de la variable específica. Es una medida de cuánto "poder" tiene una observación para cambiar el valor del coeficiente de esa variable particular.




Graficar regresión lineal múltiple

El ángulo de la línea coincide con el signo del coeficiente de la ecuación de regresión estimada y con la dirección de la pendiente.


Coeficientes:

- disp: -0.019232
- hp: -0.031229
- drat: 2.714975.



Graficar regresión lineal múltiple

Aunque no podemos trazar una sola línea de regresión ajustada en un gráfico 2-D porque tenemos múltiples variables predictoras, estas gráficas de variables añadidas nos permiten observar la relación entre cada variable predictora individual y la variable de respuesta mientras se mantienen constantes otras variables predictoras.



Referencias

- Sullivan, D. (2018). *SQL for Statistics Essential Training. Introduction to linear regression*. LinkedIn Learning.
- Pant, A. (2019). Introduction to Linear Regression and Polynomial Regression. <https://towardsdatascience.com/introduction-to-linear-regression-and-polynomial-regression-f8adc96f31cb>
- Zach. (2021). *Understanding the t-Test in Linear Regression*. <https://www.statology.org/t-test-linear-regression/>
- Zach. (2020). *The four assumptions of linear regression*. <https://www.statology.org/linear-regression-assumptions/>
- Zach. (2019). *How to Perform Multiple Linear Regression in R*. <https://www.statology.org/multiple-linear-regression-r/>