

Trabajando con y alrededor de ruido

Ignacio Díaz Oreiro
Diseño de Experimentos



Agradecimiento a la profesora Dra. Kryscia Ramírez Benavides, por facilitar material usado en esta presentación.



Introducción

- En cualquier experimento, la variabilidad que surge de un factor perturbador puede afectar los resultados.
- En general, un factor perturbador puede definirse como un factor del diseño que probablemente tenga un efecto sobre la respuesta, pero en el que no existe un interés específico.

Introducción

- En ocasiones un factor perturbador es desconocido y no controlable; es decir, se desconoce la existencia de ese factor e incluso puede tener niveles variables mientras se está realizando el experimento.
- La aleatorización es la técnica de diseño que se utiliza para protegerse contra estos factores perturbadores "que están al acecho".

Introducción

- En otros casos, el factor perturbador es conocido, pero no controlable.
- Si por lo menos puede observarse el valor que asume el factor perturbador en cada corrida del experimento, es posible hacer la compensación correspondiente en el análisis estadístico mediante el uso del análisis de covarianza.

Introducción

- Cuando la fuente de variabilidad perturbadora es conocida y controlable, puede usarse una técnica de diseño llamada formación de bloques para eliminar de manera sistemática su efecto sobre las comparaciones estadísticas entre los tratamientos.
- La formación de bloques es una técnica de diseño en extremo importante que se utiliza ampliamente en la experimentación.

Diseño de bloques completos aleatorizados

- Por ejemplo, suponga que quiere determinarse si 4 puntas diferentes producen o no lecturas diferentes en una máquina para probar la dureza de materiales.
- La máquina funciona presionando la punta en un ejemplar de prueba de metal, y por la profundidad de la depresión resultante puede determinarse la dureza.
- El experimentador ha decidido obtener 4 observaciones para cada punta.
- Hay un solo factor, el tipo de punta.

Diseño de bloques completos aleatorizados

- En un diseño completamente aleatorizado de un solo factor consistiría en asignar al azar cada una de las $4 \times 4 = 16$ corridas a una unidad experimental (cada ejemplar de prueba de metal) y observar qué resulta de la lectura de la dureza.
- Por lo tanto, se necesitarían 16 ejemplares de prueba de metal en este experimento, uno por cada corrida del diseño.
- Existe un problema: si los ejemplares difieren ligeramente en sus durezas, como podría ocurrir si se produjeron con temperaturas diferentes, los ejemplares de prueba contribuirán a la variabilidad observada en los datos de la dureza.

Diseño de bloques completos aleatorizados

- Como resultado, el error experimental reflejará *tanto* el error aleatorio *como* la variabilidad entre los ejemplares de prueba.
- El objetivo sería reducir al máximo el error experimental; es decir, eliminar del error experimental la variabilidad entre los ejemplares de prueba.
- Un diseño para lograr esto requiere que se pruebe cada punta una vez en cada uno de los cuatro ejemplares de prueba.
- A este diseño se le llama diseño de bloques completos aleatorizados (RCBD, *randomized complete block design*).

Diseño de bloques completos aleatorizados

- En el ejemplo de las puntas, el RCBD (*randomized complete block design*) se podría construir:

Ejemplar de prueba			
1	2	3	4
Punta 3	Punta 3	Punta 2	Punta 1
Punta 1	Punta 4	Punta 1	Punta 4
Punta 4	Punta 2	Punta 3	Punta 2
Punta 2	Punta 1	Punta 4	Punta 3

Diseño de bloques completos aleatorizados

- La palabra completo indica que cada bloque (ejemplar de prueba) contiene todos los tratamientos (puntas).
- Al utilizar este diseño, los bloques o ejemplares de prueba forman una unidad experimental más homogénea en la cual comparar las puntas.
- De hecho, esta estrategia de diseño mejora la precisión de las comparaciones entre las puntas al eliminar la variabilidad entre los ejemplares de prueba.
- Dentro de un bloque, el orden en que se prueban las cuatro puntas se determina aleatoriamente.

Diseño de bloques completos aleatorizados

- El RCBD es uno de los diseños experimentales más utilizados. Son numerosas las situaciones en las que el RCBD es apropiado.
- Las unidades de equipo o maquinaria de prueba son con frecuencia diferentes en sus características de operación y serían un factor de formación de bloques típico.
- Lotes de materia prima, personas y el tiempo también son fuentes de variabilidad perturbadora comunes en un experimento que pueden controlarse de manera sistemática mediante la formación de bloques.

Diseño de bloques completos aleatorizados

- La formación de bloques también puede ser útil en situaciones que no incluyen necesariamente factores perturbadores.
- Por ejemplo, suponga que un ingeniero químico está interesado en el efecto de la velocidad de alimentación del catalizador sobre la viscosidad de un polímero.
- Sabe que hay varios factores, como la fuente de la materia prima, la temperatura, el operador y la pureza de la materia prima, que son muy difíciles de controlar en un proceso a gran escala.


Diseño de bloques completos aleatorizados

- Por lo tanto, decide probar en bloques la velocidad de alimentación del catalizador, donde cada bloque consiste en alguna combinación de estos factores no controlables.
- De hecho, está utilizando los bloques para probar la robustez de su variable de proceso (la velocidad de alimentación) para las condiciones que no puede controlar con facilidad.

RCBD

Análisis estadístico del RCBD


- Suponga que se tienen, en general, a tratamientos y b bloques.
- El diseño RCBD se muestra en la figura.
- Hay una observación por tratamiento en cada bloque, y el orden en que se corren los tratamientos dentro de cada bloque se determina al azar.



RCBD

Análisis estadístico del RCBD

- Debido a que la única aleatorización de los tratamientos se hace dentro de los bloques, con frecuencia se dice que los bloques representan una restricción sobre la aleatorización.



RCBD

Análisis estadístico del RCBD

- El modelo estadístico del RCBD puede escribirse de varias maneras. El tradicional es el modelo de los efectos:

$$y_{ij} = \mu + \tau_i + \beta_j + \epsilon_{ij} \quad \begin{cases} i = 1, 2, \dots, a \\ j = 1, 2, \dots, b \end{cases}$$

- donde μ es la media global, τ_i es el efecto del tratamiento i-ésimo, β_j es el efecto del bloque j-ésimo, y ϵ_{ij} es el término del error NID(0, σ^2) usual.

- Los efectos de los tratamientos y los bloques se consideran por lo general como desviaciones de la media global, por lo que:

$$\sum_{i=1}^a \tau_i = 0 \quad \sum_{j=1}^b \beta_j = 0$$

RCBD

Análisis estadístico del RCBD

- También es posible usar un modelo de medias para el RCBD:

donde $\mu_{ij} = \mu + \tau_i + \beta_j$ $y_{ij} = \mu_{ij} + \epsilon_{ij}$ $\begin{cases} i = 1, 2, \dots, a \\ j = 1, 2, \dots, b \end{cases}$

- Aquí el interés se encuentra en probar la igualdad de las medias de los tratamientos.

Por lo tanto, las hipótesis de interés son: $H_0: \mu_1 = \mu_2 = \dots = \mu_a$

$$H_1: \text{at least one } \mu_i \neq \mu_j$$

- Puesto que la media del tratamiento i -ésimo es $\mu_i = (1/b) \sum_{j=1}^b (\mu + \tau_i + \beta_j) = \mu + \tau_i$

una manera equivalente de escribir las hipótesis anteriores es:

$$H_0: \tau_1 = \tau_2 = \dots = \tau_a = 0$$

$$H_1: \tau_i \neq 0 \text{ at least one } i$$

RCBD

Análisis estadístico del RCBD

- El procedimiento suele resumirse en un esquema de análisis de varianza:

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0
Treatments	$SS_{\text{Treatments}}$	$a - 1$	$\frac{SS_{\text{Treatments}}}{a - 1}$	$\frac{MS_{\text{Treatments}}}{MS_E}$
Blocks	SS_{Blocks}	$b - 1$	$\frac{SS_{\text{Blocks}}}{b - 1}$	
Error	SS_E	$(a - 1)(b - 1)$	$\frac{SS_E}{(a - 1)(b - 1)}$	
Total	SS_T	$N - 1$		

RCBD

Análisis estadístico del RCBD

- El procedimiento suele resumirse en un esquema de análisis de varianza:

$$F_0 = \frac{MS_{\text{Treatments}}}{MS_E}$$

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0
Treatments	$SS_{\text{Treatments}}$	$a - 1$	$\frac{SS_{\text{Treatments}}}{a - 1}$	$\frac{MS_{\text{Treatments}}}{MS_E}$
Blocks	SS_{Blocks}	$b - 1$	$\frac{SS_{\text{Blocks}}}{b - 1}$	
Error	SS_E	$(a - 1)(b - 1)$	$\frac{SS_E}{(a - 1)(b - 1)}$	
Total	SS_T	$N - 1$		

- También podría interesar comparar las medias de los bloques porque, en caso de que la diferencia entre estas medias no sea considerable, quizá no sea necesaria la formación de bloques en experimentos futuros.

RCBD

Análisis estadístico del RCBD

- Ejemplo: Un fabricante de dispositivos médicos produce injertos vasculares (venas artificiales). Estos injertos los construye combinando piezas de resina presionadas sobre tubos.
- Con frecuencia, algunos de los tubos en una serie de producción contienen defectos que causan que se rechace la unidad.
- El fabricante sospecha que la presión afecta la aparición de defectos. Sin embargo, la resina la fabrica un proveedor externo y se entrega en lotes, por lo que se sospecha que podría haber variación entre lotes.

RCBD

Análisis estadístico del RCBD

- Por lo tanto, el fabricante decide investigar el efecto de cuatro niveles diferentes de presión utilizando un diseño de bloques completos aleatorizados que considera lotes de resina como bloques.
- Habría cuatro niveles de presión (tratamientos) y seis lotes de resina (bloques).
- El orden en que se prueban las presiones dentro de cada bloque es aleatorio.
- La variable de respuesta es el rendimiento, o el porcentaje de tubos en el ciclo de producción que no contenían defectos.

RCBD

Análisis estadístico del RCBD

- Las observaciones del diseño RCBD son:

Extrusion Pressure (PSI)	Batch of Resin (Block)						Treatment Total
	1	2	3	4	5	6	
8500	90.3	89.2	98.2	93.9	87.4	97.9	556.9
8700	92.5	89.5	90.6	94.7	87.0	95.8	550.1
8900	85.5	90.8	89.6	86.2	88.0	93.4	533.5
9100	82.5	89.5	85.6	87.4	78.9	90.7	514.6
Block Totals	350.8	359.0	364.0	362.2	341.3	377.8	$y_{..} = 2155.1$

RCBD

Análisis estadístico del RCBD

- El ANOVA asociado sería:

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0	P -Value
Treatments (extrusion pressure)	178.17	3	59.39	8.11	0.0019
Blocks (batches)	192.25	5	38.45		
Error	109.89	15	7.33		
Total	480.31	23			

- Usando $\alpha = 0.05$, el valor crítico de F es $F_{0.05, 3, 15} = 3.29$. Debido a que $8.11 > 3.29$, concluimos que la presión afecta el rendimiento medio. El valor p también es pequeño.

RCBD

Análisis estadístico del RCBD

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0	P -Value
Treatments (extrusion pressure)	178.17	3	59.39	8.11	0.0019
Blocks (batches)	192.25	5	38.45		
Error	109.89	15	7.33		
Total	480.31	23			

- Además, los lotes de resina (bloques) parecen diferir significativamente, porque el cuadrado medio de los bloques es grande en relación con el error.
- Si calculamos (no lo incluye la tabla) la relación $MS_{\text{Block}} / MS_{\text{Error}} = 38.45 / 7.33 = 5.25$, que corresponderían a un valor-p de 0.006, que es significativo para $\alpha = 0.05$. Esto daría a entender que el utilizar bloques sí es significativo.

RCBD

Análisis estadístico del RCBD

- Es interesante observar los resultados que se habrían obtenido si no se hubiera tenido conocimiento de los diseños de bloques aleatorizados.
- Suponga que este experimento se ejecutó como un diseño completamente aleatorio y (por casualidad) se obtuvieron las mismas observaciones apuntadas antes.
- El análisis incorrecto de estos datos como un diseño de factor único completamente aleatorizado sería:

RCBD

Análisis estadístico del RCBD

- El análisis incorrecto de estos datos como un diseño de factor único completamente aleatorizado sería:

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0	P -Value
Extrusion pressure	178.17	3	59.39	3.95	0.0235
Error	302.14	20	15.11		
Total	480.31	23			

- El valor- $p = 0.0235$, que es menor que $\alpha = 0.05$, por lo que la hipótesis nula también se rechazaría. Sin embargo, el error aumentó considerablemente.

RCBD

Análisis estadístico del RCBD

- El MS_{Error} pasó de 7.33 a 15.11.
- Toda la variabilidad debida a los bloques está ahora en el término de error.

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0	P -Value
Treatments (extrusion pressure)	178.17	3	59.39	8.11	0.0019
Blocks (batches)	192.25	5	38.45		
Error	109.89	15	7.33		
Total	480.31	23			

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0	P -Value
Extrusion pressure	178.17	3	59.39	3.95	0.0235
Error	302.14	20	15.11		
Total	480.31	23			

RCBD

Análisis estadístico del RCBD

- Esto permite ver por qué se llama al RCBD una técnica de diseño de reducción de ruido.
- Otro punto importante. Si un experimentador falla en bloquear cuando debería haberlo hecho, el efecto puede ser inflar el error experimental, y sería posible inflar tanto el error que no podrían identificarse diferencias importantes entre las medias de tratamiento.

RCBD

Análisis estadístico del RCBD

- Se deberá, como es usual, verificar la adecuación del modelo supuesto.
- En general, deberá estarse alerta a los problemas potenciales con el supuesto de normalidad, con la desigualdad de la varianza por tratamiento o bloque, y con la interacción bloque-tratamiento.
- Como en el diseño completamente aleatorizado, el análisis de residuales es la herramienta principal que se utiliza en estos diagnósticos de verificación.

RCBD

Análisis estadístico del RCBD

- El modelo estadístico lineal que se ha usado para el diseño de bloques aleatorizados es completamente aditivo: $y_{ij} = \mu + \tau_i + \beta_j + \epsilon_{ij}$
- Sin embargo, hay situaciones en las que podrían encontrarse interacciones entre tratamiento y bloque, por ejemplo, solo uno de los bloques se ve afectado reflejando una interacción.
- El análisis de residuales y otros procedimientos de verificación pueden ser útiles para detectar la no aditividad.

RCBD

Análisis estadístico del RCBD

- Si una interacción está presente, puede afectar seriamente el análisis de varianza y posiblemente lo invalide.
- En general, la presencia de una interacción infla el cuadrado medio del error y puede afectar adversamente la comparación de las medias de los tratamientos.
- En situaciones en las que ambos factores, así como su posible interacción, son de interés, deben usarse diseños factoriales.

Diseño del cuadrado latino

- El diseño RCBD sirve para reducir el error residual de un experimento al eliminar la variabilidad debida a una variable perturbadora conocida y controlable.
- Hay otros tipos de diseños que utilizan el principio de la formación de bloques cuando más de una variable perturbadora entra en juego.
- Por ejemplo, suponga que un experimentador estudia los efectos que tienen cinco formulaciones diferentes de la carga propulsora utilizada en los sistemas de expulsión de la tripulación de un avión, basado en la rapidez de combustión.

Diseño del cuadrado latino

- Cada formulación se hace con un lote de materia prima que sólo alcanza para probar cinco formulaciones.
- Además, las formulaciones son preparadas por varios operadores, y puede haber diferencias sustanciales en las habilidades y experiencia de los operadores.
- Por lo tanto, al parecer hay dos factores perturbadores que serán "calculados en promedio" en el diseño: los lotes de materia prima y los operadores.

Diseño del cuadrado latino

- El diseño apropiado para este problema consiste en probar cada formulación exactamente una vez en cada lote de materia prima y que cada formulación sea preparada exactamente una vez por cada uno de los cinco operadores.

Batches of Raw Material	Operators				
	1	2	3	4	5
1	<i>A = 24</i>	<i>B = 20</i>	<i>C = 19</i>	<i>D = 24</i>	<i>E = 24</i>
2	<i>B = 17</i>	<i>C = 24</i>	<i>D = 30</i>	<i>E = 27</i>	<i>A = 36</i>
3	<i>C = 18</i>	<i>D = 38</i>	<i>E = 26</i>	<i>A = 27</i>	<i>B = 21</i>
4	<i>D = 26</i>	<i>E = 31</i>	<i>A = 26</i>	<i>B = 23</i>	<i>C = 22</i>
5	<i>E = 22</i>	<i>A = 30</i>	<i>B = 20</i>	<i>C = 29</i>	<i>D = 31</i>

Diseño del cuadrado latino

- Al diseño resultante se le llama diseño de cuadrado latino.
- Observe que el diseño es un arreglo cuadrado y que las cinco formulaciones (o tratamientos) se denotan por las letras latinas A, B, C, D y E; de ahí el nombre de cuadrado latino.

Batches of Raw Material	Operators				
	1	2	3	4	5
1	$A = 24$	$B = 20$	$C = 19$	$D = 24$	$E = 24$
2	$B = 17$	$C = 24$	$D = 30$	$E = 27$	$A = 36$
3	$C = 18$	$D = 38$	$E = 26$	$A = 27$	$B = 21$
4	$D = 26$	$E = 31$	$A = 26$	$B = 23$	$C = 22$
5	$E = 22$	$A = 30$	$B = 20$	$C = 29$	$D = 31$

Diseño del cuadrado latino

- El diseño de cuadrado latino se usa para eliminar dos fuentes de variabilidad perturbadora; es decir, permite hacer la formación de bloques sistemática en dos direcciones.
- Por lo tanto, los renglones y las columnas representan en realidad dos restricciones sobre la aleatorización.
- En general, un cuadrado latino para p factores, o cuadrado latino $p \times p$, es un cuadrado con p renglones y p columnas.

Diseño del cuadrado latino

- Cada una de las p^2 celdas resultantes contiene una de las p letras que corresponde a los tratamientos, y cada letra ocurre una y sólo una vez en cada renglón y columna.

- Algunos ejemplos de cuadrados latinos son:

4×4

A B D C
B C A D
C D B A
D A C B

5×5

A D B E C
D A C B E
C B E D A
B E A C D
E C D A B

6×6

A D C E B F
B A E C F D
C E D F A B
D C F B E A
F B A D C E
E F B A D C

Diseño del cuadrado latino

- El modelo estadístico de un cuadrado latino es:

$$y_{ijk} = \mu + \alpha_i + \tau_j + \beta_k + \epsilon_{ijk} \begin{cases} i = 1, 2, \dots, p \\ j = 1, 2, \dots, p \\ k = 1, 2, \dots, p \end{cases}$$

- donde y_{ijk} representa la observación en el renglón i -ésimo y la columna k -ésima para el tratamiento j -ésimo, μ es la media global, α_i es el efecto del renglón i -ésimo, τ_j es el efecto del tratamiento j -ésimo, β_k es el efecto de la columna k -ésimo y ϵ_{ijk} es el error aleatorio.

Diseño del cuadrado latino

$$y_{ijk} = \mu + \alpha_i + \tau_j + \beta_k + \epsilon_{ijk} \begin{cases} i = 1, 2, \dots, p \\ j = 1, 2, \dots, p \\ k = 1, 2, \dots, p \end{cases}$$

- Observe que se trata de un modelo de efectos
- El modelo aquí descrito es completamente aditivo; es decir, no hay interacción entre renglones, columnas y tratamientos.
- Se podría también agregar interacciones, particularmente interesante la interacción entre factores de diseño.

Diseño del cuadrado latino

- El procedimiento de cálculo para el análisis de varianza sería:

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0
Treatments	$SS_{\text{Treatments}} = \frac{1}{p} \sum_{j=1}^p y_{.j}^2 - \frac{y_{..}^2}{N}$	$p - 1$	$\frac{SS_{\text{Treatments}}}{p - 1}$	$F_0 = \frac{MS_{\text{Treatments}}}{MS_E}$
Rows	$SS_{\text{Rows}} = \frac{1}{p} \sum_{i=1}^p y_{i.}^2 - \frac{y_{..}^2}{N}$	$p - 1$	$\frac{SS_{\text{Rows}}}{p - 1}$	
Columns	$SS_{\text{Columns}} = \frac{1}{p} \sum_{k=1}^p y_{..k}^2 - \frac{y_{..}^2}{N}$	$p - 1$	$\frac{SS_{\text{Columns}}}{p - 1}$	
Error	SS_E (by subtraction)	$(p - 2)(p - 1)$	$\frac{SS_E}{(p - 2)(p - 1)}$	
Total	$SS_T = \sum_i \sum_j \sum_k y_{ijk}^2 - \frac{y_{..}^2}{N}$	$p^2 - 1$		

Diseño del cuadrado grecolatino

- Considere un cuadrado latino $p \times p$ al cual se le superpone un segundo cuadrado latino $p \times p$ en el que los tratamientos se denotan con letras griegas.
- Si cuando se hace la superposición los dos cuadrados tienen la propiedad de que cada letra griega aparece una y sólo una vez con cada letra latina, al diseño obtenido se le llama cuadrado grecolatino.

Diseño del cuadrado grecolatino

- La siguiente tabla muestra un ejemplo de cuadrado grecolatino:

Row	Column			
	1	2	3	4
1	$A\alpha$	$B\beta$	$C\gamma$	$D\delta$
2	$B\delta$	$A\gamma$	$D\beta$	$C\alpha$
3	$C\beta$	$D\alpha$	$A\delta$	$B\gamma$
4	$D\gamma$	$C\delta$	$B\alpha$	$A\beta$

Diseño del cuadrado grecolatino

- El diseño de cuadrado grecolatino puede usarse para controlar sistemáticamente tres fuentes de variabilidad extraña, es decir, para hacer la formación de bloques en tres direcciones.

Row	Column			
	1	2	3	4
1	$A\alpha$	$B\beta$	$C\gamma$	$D\delta$
2	$B\delta$	$A\gamma$	$D\beta$	$C\alpha$
3	$C\beta$	$D\alpha$	$A\delta$	$B\gamma$
4	$D\gamma$	$C\delta$	$B\alpha$	$A\beta$

- El diseño permite la investigación de cuatro factores (renglones, columnas, letras latinas y letras griegas), cada una con p niveles en sólo p^2 corridas.

Diseño del cuadrado grecolatino

- El modelo estadístico de un cuadrado grecolatino es:

$$y_{ijkl} = \mu + \theta_i + \tau_j + \omega_k + \Psi_l + \epsilon_{ijkl} \begin{cases} i = 1, 2, \dots, p \\ j = 1, 2, \dots, p \\ k = 1, 2, \dots, p \\ l = 1, 2, \dots, p \end{cases}$$

- donde y_{ijkl} representa la observación en el renglón i -ésimo y la columna l -ésima para la letra latina j y la letra griega k , el tratamiento j -ésimo, μ es la media global, θ_i es el efecto del renglón i -ésimo, τ_j es el efecto de la letra latina j , ω_k es el efecto de la letra griega k , ψ_l es el efecto de la columna l y ϵ_{ijkl} es el error aleatorio.

Diseño del cuadrado grecolatino

$$y_{ijkl} = \mu + \theta_i + \tau_j + \omega_k + \Psi_l + \epsilon_{ijkl} \begin{cases} i = 1, 2, \dots, p \\ j = 1, 2, \dots, p \\ k = 1, 2, \dots, p \\ l = 1, 2, \dots, p \end{cases}$$

- El análisis de varianza es muy parecido al de un cuadrado latino.
- Puede calcularse una suma de cuadrados debida al factor de las letras griegas a partir de los totales de las letras griegas y el error experimental se reduce adicionalmente en esta cantidad.

Diseño del cuadrado grecolatino

- Los cálculos serían:

Source of Variation	Sum of Squares	Degrees of Freedom
Latin letter treatments	$SS_L = \frac{1}{p} \sum_{j=1}^p y_{j..}^2 - \frac{y_{....}^2}{N}$	$p - 1$
Greek letter treatments	$SS_G = \frac{1}{p} \sum_{k=1}^p y_{..k}^2 - \frac{y_{....}^2}{N}$	$p - 1$
Rows	$SS_{\text{Rows}} = \frac{1}{p} \sum_{i=1}^p y_{i...}^2 - \frac{y_{....}^2}{N}$	$p - 1$
Columns	$SS_{\text{Columns}} = \frac{1}{p} \sum_{l=1}^p y_{...l}^2 - \frac{y_{....}^2}{N}$	$p - 1$
Error	SS_E (by subtraction)	$(p - 3)(p - 1)$
Total	$SS_T = \sum_i \sum_j \sum_k \sum_l y_{ijkl}^2 - \frac{y_{....}^2}{N}$	$p^2 - 1$

Diseño del cuadrado grecolatino

- La hipótesis nula de la igualdad de tratamientos de renglones, columnas, letras latinas y letras griegas se probaría dividiendo el cuadrado medio correspondiente por el cuadrado medio del error.

Source of Variation	Sum of Squares	Degrees of Freedom
Latin letter treatments	$SS_L = \frac{1}{p} \sum_{j=1}^p y_{j..}^2 - \frac{y_{....}^2}{N}$	$p - 1$
Greek letter treatments	$SS_G = \frac{1}{p} \sum_{k=1}^p y_{..k.}^2 - \frac{y_{....}^2}{N}$	$p - 1$
Rows	$SS_{\text{Rows}} = \frac{1}{p} \sum_{i=1}^p y_{i..}^2 - \frac{y_{....}^2}{N}$	$p - 1$
Columns	$SS_{\text{Columns}} = \frac{1}{p} \sum_{l=1}^p y_{...l}^2 - \frac{y_{....}^2}{N}$	$p - 1$
Error	SS_E (by subtraction)	$(p - 3)(p - 1)$
Total	$SS_T = \sum_i \sum_j \sum_k \sum_l y_{ijkl}^2 - \frac{y_{....}^2}{N}$	$p^2 - 1$

- La región de rechazo es la cola superior del punto de la distribución $F_{(p-1), (p-3)(p-1)}$

Diseños de bloques incompletos balanceados

- En ciertos experimentos que utilizan diseños de bloques aleatorios, es posible que no podamos ejecutar todas las combinaciones de tratamientos en cada bloque.
- Situaciones como ésta suelen ocurrir debido a la escasez de aparatos o instalaciones experimentales o al tamaño físico del bloque.
- Para este tipo de problemas es posible utilizar diseños de bloques aleatorios en los que no todos los tratamientos están presentes en cada bloque.

Diseños de bloques incompletos balanceados

- Cuando todas las comparaciones de tratamientos son igualmente importantes, las combinaciones de tratamientos utilizadas en cada bloque deben seleccionarse de manera equilibrada, de modo que cualquier par de tratamientos ocurran juntos el mismo número de veces que cualquier otro par.
- A esto se le llama un diseño de bloques incompletos balanceados, o BIBD, por *balanced incomplete block design*).

Diseños de bloques incompletos balanceados


- Por ejemplo, los tratamientos 1 y 3 aparecen dos veces (en los bloques 1 y 2).
- Los tratamientos 2 y 4 aparecen en los bloques 3 y 4.

Balanced Incomplete Block Design for Catalyst Experiment

Treatment (Catalyst)	Block (Batch of Raw Material)				y_i
	1	2	3	4	
1	73	74	—	71	218
2	—	75	67	72	214
3	73	75	68	—	216
4	75	—	72	75	222
y_j	221	224	207	218	$870 = y_{..}$

Diseños de bloques incompletos balanceados

- Existen tablas para diseños BIBD creadas por Fisher y Yates (1953), Davies (1956) y Cochran y Cox (1957), entre otros.
- Por ejemplo, se cuenta con 6 tratamientos (A, B, C, D, E, F) y solo se pueden aplicar 3 tratamientos en cada bloque. Un posible diseño sería:



Análisis de covarianza

- El análisis de covarianza (ANCOVA) es otra técnica que en ocasiones es útil para mejorar la precisión de un experimento.
- Suponga que en un experimento con una variable de respuesta y existe otra variable x que se relaciona linealmente con y .
- Además, suponga que x no puede ser controlada por el experimentador, pero puede observarse junto con y .
- A la variable x se le llama variable concomitante o covariable.

Análisis de covarianza

- El análisis de covarianza implica ajustar la variable de respuesta observada para el efecto de la variable concomitante.
- Si no se hace este ajuste, la variable concomitante podría inflar el cuadrado medio del error y hacer que sean más difíciles de detectar las verdaderas diferencias en la respuesta debidas a los tratamientos.
- Por lo tanto, el análisis de covarianza es un método de ajuste para los efectos de una variable perturbadora no controlable.

Análisis de covarianza

- Por ejemplo, considere el estudio realizado para determinar si existe una diferencia en la resistencia de una fibra de monofilamento producida por tres máquinas diferentes.
- Sin embargo, la resistencia de una fibra se relaciona con su diámetro, siendo las fibras más gruesas, en general, más resistentes que las más delgadas.
- Se selecciona una muestra aleatoria de cinco ejemplares de prueba de fibra de cada máquina.


Análisis de covarianza

- Los datos de este experimento muestran la resistencia de la fibra a la ruptura en libras (y) y el diámetro en 10^{-3} pulgadas (x) de cada ejemplar:
- Cabe indicar que el diámetro es medible. Es un factor perturbador no controlable pero medible.
- Además, es una variable continua.

Machine 1		Machine 2		Machine 3	
y	x	y	x	y	x
36	20	40	22	35	21
41	25	48	28	37	23
39	24	39	22	42	26
42	25	45	30	34	21
49	32	44	28	32	15
207	126	216	130	180	106

Análisis de covarianza

- El diagrama de dispersión de la resistencia (y) contra el diámetro (x) muestra que la resistencia de la fibra también se afecta por su grosor: una fibra más gruesa será por lo general más resistente que una delgada.
- El análisis de covarianza podría usarse para eliminar el efecto del grosor (x) sobre la resistencia (y) cuando se prueban las diferencias en la resistencia entre las máquinas.



Modelo estadístico

- Suponiendo que existe una relación lineal entre la respuesta y la covariable, un modelo estadístico apropiado es:

$$y_{ij} = \mu + \tau_i + \beta(x_{ij} - \bar{x}_{..}) + \epsilon_{ij} \quad \begin{cases} i = 1, 2, \dots, a \\ j = 1, 2, \dots, n \end{cases}$$

- Donde y_{ij} es la observación j -ésima de la variable de respuesta tomada bajo el tratamiento o nivel i -ésimo del único factor, x_{ij} es la medición hecha de la covariable correspondiente a y_{ij} (es decir, la corrida ij -ésima), $\bar{x}_{..}$ es la media de los valores x_{ij} , μ es la media global, τ_i es el efecto del tratamiento i -ésimo, β es el coeficiente de regresión lineal que indica la dependencia de y_{ij} de x_{ij} y ϵ_{ij} es el componente del error aleatorio, $NID(0, \sigma^2)$.

Modelo estadístico

$$y_{ij} = \mu + \tau_i + \beta(x_{ij} - \bar{x}_{..}) + \epsilon_{ij} \quad \begin{cases} i = 1, 2, \dots, a \\ j = 1, 2, \dots, n \end{cases}$$

- Se supone que la pendiente $\beta \neq 0$ y que la verdadera relación entre y_{ij} y x_{ij} es lineal, que los coeficientes de regresión de cada tratamiento son idénticos, que la suma de los efectos de los tratamientos es cero, y que la variable concomitante x_{ij} no se afecta por los tratamientos.
- Observe que el modelo del análisis de covarianza es una combinación de los modelos lineales empleados en el análisis de varianza y regresión.
- Se tienen efectos de los tratamientos τ_i como en un análisis de varianza de un solo factor, y un coeficiente de regresión β , como en una ecuación de regresión.

Modelo estadístico

$$y_{ij} = \mu + \tau_i + \beta(x_{ij} - \bar{x}_{..}) + \epsilon_{ij} \quad \begin{cases} i = 1, 2, \dots, a \\ j = 1, 2, \dots, n \end{cases}$$

- La variable concomitante se expresa como $(x_{ij} - \bar{x}_{..})$ en lugar de x_{ij} , para que el parámetro μ se preserve como la media global.
- Se supone que la pendiente $\beta \neq 0$ y que la verdadera relación entre y_{ij} y x_{ij} es lineal, que los coeficientes de regresión de cada tratamiento son idénticos, que la suma de los efectos de los tratamientos es cero, y que la variable concomitante x_{ij} no se afecta por los tratamientos.

Análisis de covarianza

Modelo estadístico


- Para los cálculos se utilizan sumas de cuadrados y el análisis de covarianza puede verse como un análisis de varianza ajustado para considerar el efecto de la covariable.

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0
Regression	$(S_{xy})^2/S_{xx}$	1		
Treatments	$SS'_E - SS_E = S_{yy} - (S_{xy})^2/S_{xx} - [E_{yy} - (E_{xy})^2/E_{xx}]$	$a - 1$	$\frac{SS'_E - SS_E}{a - 1}$	$\frac{(SS'_E - SS_E)/(a - 1)}{MS_E}$
Error	$SS_E = E_{yy} - (E_{xy})^2/E_{xx}$	$a(n - 1) - 1$	$MS_E = \frac{SS_E}{a(n - 1) - 1}$	
Total	S_{yy}	$an - 1$		

Análisis de covarianza

- En el ejemplo anterior, donde se quería determinar si existía diferencia en si la resistencia de la fibra a la ruptura (y) debido a las máquinas, pero tomando en cuenta el diámetro (x) de cada ejemplar, se calcula F_0 y se obtiene $F_0 = 2.61$
- Al comparar este valor de F_0 con $F_{0.10, 2, 11} = 2.86$, se encuentra que no puede rechazarse la hipótesis nula.


Machine 1		Machine 2		Machine 3	
y	x	y	x	y	x
36	20	40	22	35	21
41	25	48	28	37	23
39	24	39	22	42	26
42	25	45	30	34	21
49	32	44	28	32	15
207	126	216	130	180	106



Análisis de covarianza

- El valor-p de este estadístico de la prueba es $p = 0.1181$.
- Por lo tanto, no hay evidencia sólida de que las fibras producidas por las tres máquinas difieran en la resistencia a la ruptura.

Machine 1		Machine 2		Machine 3	
y	x	y	x	y	x
36	20	40	22	35	21
41	25	48	28	37	23
39	24	39	22	42	26
42	25	45	30	34	21
49	32	44	28	32	15
207	126	216	130	180	106



Análisis de covarianza

- Es interesante observar lo que habría ocurrido en este experimento si no se hubiera realizado el análisis de covarianza, es decir, si los datos de la resistencia a la ruptura (y) se hubieran analizado como un experimento de un solo factor en el que se ignorara la covariable x.

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0	P -Value
Machines	140.40	2	70.20	4.09	0.0442
Error	206.00	12	17.17		
Total	346.40	14			

Análisis de covarianza

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0	P -Value
Machines	140.40	2	70.20	4.09	0.0442
Error	206.00	12	17.17		
Total	346.40	14			

- Se concluiría, con base en este análisis, que las máquinas sí difieren significativamente en la resistencia de la fibra producida.
- Es exactamente la conclusión opuesta del análisis de covarianza.
- Si se sospechara que las máquinas difieren significativamente en su efecto sobre la resistencia de la fibra, entonces se intentaría igualar la resistencia producida por las tres máquinas.

Análisis de covarianza

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0	P -Value
Machines	140.40	2	70.20	4.09	0.0442
Error	206.00	12	17.17		
Total	346.40	14			

- Sin embargo, en este problema las máquinas no difieren en la resistencia de la fibra producida después de que se elimina el efecto lineal del diámetro.
- Sería conveniente reducir la variabilidad del diámetro de la fibra dentro de las máquinas, ya que con esto probablemente se reduciría la variabilidad de la resistencia de la fibra.

ANCOVA en R

- Realizaremos un ANCOVA para probar si la técnica de estudio tiene o no un impacto en los puntajes de los exámenes utilizando las siguientes variables:
 - Técnica de estudio: Variable independiente a analizar
 - Nota actual del alumno: Covariable que se quiere considerar
 - Puntuación del examen: Variable de respuesta
- Se cuenta con un conjunto de datos de 90 estudiantes que se dividieron aleatoriamente en tres grupos de 30.

ANCOVA en R

- El conjunto de datos muestra la técnica de estudio que usó cada estudiante (A, B o C), su calificación actual en la clase cuando comenzaron a usar la técnica de estudio y la calificación que recibieron en el examen después de usar la técnica de estudio durante un mes para prepararse para el examen.

#	technique	current_grade	exam
#1	A	80.22435	87.32759
#2	A	74.20306	90.67114
#3	A	77.80723	88.87902
#4	A	85.79306	87.75735
#5	A	67.55408	85.72442
#6	A	71.76310	92.52167

ANCOVA en R

- Un supuesto que es necesario validar es que la covariable y el tratamiento son independientes.
- Agregar un término de covariable en el modelo solo tiene sentido si:
 - La covariable está asociada con la variable respuesta (para reducir el error residual).
 - La covariable no está influenciada por el tratamiento (independencia entre covariable y tratamiento).

ANCOVA en R

- En el ejemplo se debe verificar que la covariable (*current_grade*) y el tratamiento (*technique*) sean independientes entre sí.
- Agregar un término de covariable al modelo solo tiene sentido si la covariable y el tratamiento actúan de forma independiente sobre la variable de respuesta.
- Si la covariable no se relaciona con la respuesta: El ajuste no reduce el error residual (ANOVA simple sería suficiente).

ANCOVA en R

- Para verificar que la covariable y el tratamiento son independientes, podemos ejecutar un ANOVA usando *current_grade* como variable de respuesta y *technique* como variable predictora:

```
#fit anova model
anova_model <- aov(current_grade ~ technique, data = data)
#view summary of anova model
summary(anova_model)
```

#	Df	Sum Sq	Mean Sq	F value	Pr(>F)
#technique	2	74	37.21	0.599	0.552
#Residuals	87	5406	62.14		

- El valor de p es superior a 0.05, por lo que la covariable y el tratamiento parecen ser independientes.

ANCOVA en R

- Otra forma es usar una regresión lineal entre `current_grade` y `technique`:

```
lm(formula = current_grade ~ technique, data = data)

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  80.4059     1.5150  53.073  <2e-16 ***
techniqueB    1.7796     2.1425   0.831   0.408
techniqueC   -0.9556     2.1425  -0.446   0.657
---
Residual standard error: 8.298 on 87 degrees of freedom
Multiple R-squared:  0.01893,    Adjusted R-squared:  -0.00362
F-statistic: 0.8395 on 2 and 87 DF,  p-value: 0.4354
```

- Puede verse por el coeficiente de determinación R^2 (muy bajo, 0.01893) y el valor p (0.4354) que *technique* no aporta significativamente a *current_grade*.

ANCOVA en R

- A continuación, ajustaremos el modelo ANCOVA utilizando la función `aov()` que utiliza la suma de cuadrados tipo I, en el que las variables del modelo se analizan secuencialmente.
- Para este caso, pondremos primero la covariable *current_grade*:

```
anova_model_2 <- aov(exam ~ current_grade + technique, data = data)
summary(anova_model_2)
```

- La función `aov()` calculará primero la suma de cuadrados de *current_grade* (covariable), y posteriormente, la suma de cuadrados de *technique*.

ANCOVA en R

- El resultado obtenido es:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
current_grade	1	0	0.0	0.00	0.986
technique	2	1243	621.5	17.48	4.26e-07 ***
Residuals	86	3057	35.5		

- El valor p para *technique* es extremadamente pequeño, lo que indica que la técnica de estudio tiene un efecto estadísticamente significativo en las puntuaciones de los exámenes, incluso después de controlar la calificación actual (*current_grade*).

ANCOVA en R

- Otra forma equivalente es utilizar la función `Anova()` del paquete “car”, dado que esta función permite especificar qué tipo de suma de cuadrados queremos utilizar (II ó III).
- Si usamos `Anova()` podemos usar cualquier orden en los predictores del modelo:

```
#load car library
library(car)

#fit ANCOVA model
ancova_model <- aov(exam ~ technique + current_grade, data = data)
```

Análisis de covarianza

ANCOVA en R

```
#fit ANCOVA model
```

```
ancova_model <- aov(exam ~ technique + current_grade, data = data)
```

```
#view summary of model
```

```
Anova(ancova_model, type="III")
```

```
#Response: exam
```

#	Sum Sq	Df	F value	Pr(>F)
\$(Intercept)	7161.2	1	201.4621	< 2.2e-16 ***
#technique	1242.9	2	17.4830	4.255e-07 ***
#current_grade	12.3	1	0.3467	0.5576
#Residuals	3057.0	86		

- Podemos ver que *technique* es significativa y que el valor F es el mismo que en el modelo anterior.
- En este caso sin consideración de interacción, el “tipo II” produce resultados equivalentes.

ANOVA. Tipos I, II, III

- Los tipos de ANOVA surgen de cuando los datos están desbalanceados, por lo que hay al menos 3 formas de calcular las sumas de cuadrados, comúnmente llamados sumas de cuadrados de tipo I, II y III.
- Por ejemplo, un modelo que incluye dos factores A y B tiene dos efectos principales y una interacción, AB. Este modelo se representa por $SS(A, B, AB)$.
- El modelo: $SS(A, B)$ indica el modelo sin interacción, $SS(B, AB)$ indica el modelo que no tiene en cuenta los efectos del factor A, por nombrar algunos.

ANOVA. Tipos I, II, III

- La notación muestra las diferencias incrementales en sumas de cuadrados
- Por ejemplo, $SS(AB | A, B)$ representa “la suma de cuadrados para la interacción después de los efectos principales”.
- $SS(A | B)$ es “la suma de cuadrados para el efecto principal A después del efecto B principal e ignorando las interacciones”.
- Surgen entonces los diferentes tipos de sumas de cuadrados.

ANOVA. Tipos I, II, III

- Tipo I, también llamado suma de cuadrados “secuencial”:
 - $SS(A)$ para el factor A.
 - $SS(B | A)$ para el factor B.
 - $SS(AB | B, A)$ para la interacción AB.
- Esto prueba el efecto principal del factor A, seguido del efecto principal del factor B después del efecto principal de A, seguido del efecto de interacción AB después de los efectos principales.

ANOVA. Tipos I, II, III

- Debido a la naturaleza secuencial y al hecho de que los dos factores principales se prueban en un orden particular, el Tipo I de sumas de cuadrados dará diferentes resultados para datos no balanceados dependiendo de qué efecto principal se considere primero.

ANOVA. Tipos I, II, III

- Tipo II:
 - $SS(A | B)$ para el factor A.
 - $SS(B | A)$ para el factor B.
- Este tipo prueba cada efecto principal después del otro efecto principal.
- Se debe tener en cuenta que no se supone una interacción significativa (en otras palabras, primero se debe probar la interacción ($SS(AB | A, B)$) y solo si AB no es significativa, se continúa con el análisis de los efectos principales).

ANOVA. Tipos I, II, III

- Tipo III:
 - $SS(A | B, AB)$ para el factor A.
 - $SS(B | A, AB)$ para el factor B.
- Este tipo prueba la presencia de un efecto principal después del otro efecto principal e interacción. Por lo tanto, este enfoque es válido en presencia de interacciones significativas.

ANOVA. Tipos I, II, III

- Sin embargo, a menudo no es interesante interpretar un efecto principal si hay interacciones (en términos generales, si hay una interacción significativa, podrían no tener sentido analizar los efectos principales).
- Si las interacciones no son significativas, el tipo II da una prueba más poderosa.

Referencias

- Montgomery, D.C. (2013). *Design of Experiments*. John Wiley & sons.
- Zach. (2019). *How to Conduct an ANCOVA in R*.
<https://www.statology.org/ancova-in-r/>

