



UNIVERSIDAD DE
COSTA RICA




ECCI

Escuela de Ciencias de la
Computación e Informática

Big Data

*Dr. Luis Gustavo Esquivel
Quirós*

*Escuela de Ciencias de la
Computación e Informática
Universidad de Costa Rica*



"Big Data"



English Wikipedia

≈ 63 millones de artículos

En Mayo de 2019: 550GB bz2,
190GB 7z. En Marzo 2022, 1.4TB
sin comprimir
(Texto; Datos actuales)
(XML; comprimido)

WIKIPEDIA
The Free Encyclopedia

"Big Data"




Wikimedia Commons

≈ 405 TB de datos

≈ 93 millones de archivos
(2023)



"Big Data"




"Big Data"

Twitter

≈ 12 TB / día

≈ 450 millones de usuarios activos
al mes

A large, light blue Twitter bird logo is centered in the background, spanning across the white and yellow horizontal bands.

twitter

"Big Data"



Large Hadron Collider

≈ 68 TB / día

≈ 90 PB / año

≈ Siete billones de archivos (2022)



"Big Data"


Facebook

≈ 4 PB / día

≈ 2.98 billones de usuarios activos
al mes



"Big Data"

The background of the slide features a large, semi-transparent watermark of the TikTok logo, which is a stylized musical note in cyan and red, centered behind the text.

TicTok

≈ 1 billón de usuarios activos al mes
(2021)

≈ 83% de los usuarios han
publicado un video

"Big Data"

Vigilancia de la NSA

≈ 29 PB / día

≈ 568,627 Wiki / día

(2013, procesados)




"Big Data"

Google

≈ 200 PB / día

≈ 8.5 billones de búsquedas al día
(2022)



"Big Data"



El tráfico de Internet


≈ 29.3 billones de dispositivos de red

≈ 5.3 billones de usuarios

(2023, estimaciones de Cisco)

Los datos: Un cuello de botella moderno?





Volumen de datos

Se esperaban 44 zettabytes (ZB) para 2020.




DATA NEVER SLEEPS 10.0

Volumen de datos

<https://www.domo.com/learn/infographic/data-never-sleeps-10>

Over the last ten years, digital engagement through social media, streaming content, online purchasing, peer-to-peer payments and other activities has increased hundreds and even thousands of percentage points. While the world has faced a pandemic, economic ups and downs, and global unrest, there has been one constant in society:

our increasing use of new digital tools to support our personal and business needs, from connecting and communicating to conducting transactions and business. In this 10th annual "Data Never Sleeps" infographic, we share a glimpse at just how much data the internet produces each minute from some of this activity, marveling at the volume and variety of information that has been generated.



DATA NEVER SLEEPS 1.0 VS. 10.0



GLOBAL INTERNET POPULATION GROWTH IN BILLIONS



To succeed in an increasingly digital world where the volume of data created keeps accelerating, businesses need the right tools to put that data to work right where work gets done. Domo gives you the power to rapidly unlock value from all your data, regardless of where it lives, and drive actions across your organization that will improve business outcomes. Every click, swipe, share, or like tells a story, and Domo

Características

Crecen mucho y muy rápidamente.

Pueden ser: estructurados, semiestructurados y no estructurados . . .


Se considera que los datos no estructurados en el mundo suponen el 80%!



Difíciles de almacenar



Procesarlos es difícil



Tratamiento
distribuido

Unir todos los datos

Costos de equipos
(escalado)

Procesamiento
eficiente de
grandes volúmenes
de datos (Batch . . .
50 años!!)

Big Data

Big Data es un término que se aplica a los conjuntos de datos cuyo tamaño está más allá de la capacidad de herramientas disponibles para llevar a cabo su adquisición, acceso, análisis y/o la aplicación en una cantidad de tiempo razonable.

Big Data (Google research)


Históricamente, la mayoría de las decisiones (políticas, militares, comerciales y personales) las han tomado cerebros [que] tienen una lógica impredecible y operan sobre la base de la evidencia experimental subjetiva. “Big data” representa un cambio cultural en el que cada vez más decisiones se toman mediante algoritmos con “lógica transparente”, que operan sobre evidencia documentada inmutable. Creo que “grande” se refiere más a la naturaleza generalizada de este cambio que a una cantidad particular de datos.

Big Data

- Una de las primeras definiciones de Big data fue presentada por Laney en el 2001 indicando que: “Big data son activos de información de gran volumen, alta velocidad y gran variedad que exigen formas rentables e innovadoras de procesamiento de información para mejorar la comprensión y la toma de decisiones”



Big Data



Big Data: Volumen

- Cantidad de datos generados, por ejemplo:
 - ✓ exabyte, zettabytes o yottabytes.
- Las razones del aumento del volumen de datos son:
 - ✓ El aumento del número de fuentes de datos, por ejemplo:
 - Sensores de mayor resolución
 - Infraestructura escalable


Big Data: Velocidad

- La velocidad con la que se generan los datos
- El proceso de generación de datos nunca se detiene, aumentando la velocidad a la que los datos se transforman en conocimiento
- Los datos se obtienen de la transmisión casi real o en tiempo real de tecnologías locales o basadas en la nube gracias a la mejora de la conectividad


Big Data: Variedad

- Tipos de datos provenientes de diferentes fuentes, por ejemplo:
 - ✓ Máquinas, personas, procesos, entre otros.
- Estos datos pueden estar estructurados o no estructurados con variedad de representaciones, por ejemplo:
 - ✓ Texto, imagen, video, datos de dispositivos portátiles, de sensores, entre otros.

Big Data = Transactions + Interactions + Observations



Source: Contents of above graphic created in partnership with Teradata, Inc.



Componentes



BIG DATA



VOLUME

DATA SIZE



VELOCITY

SPEED OF CHANGE



VARIETY

DIFFERENT FORMS
OF DATA SOURCES



VERACITY

UNCERTAINTY OF
DATA

Big Data: Veracidad

- La calidad y el origen de los datos que definen su coherencia, exhaustividad e integridad.
- Dado que la mayoría de los datos no están estructurados, es necesario categorizarlos, analizarlos y visualizarlos para garantizar su calidad.

Las 5 V's del Big Data

Tiene el objetivo de extraer información de valor de los datos. Hace referencia a técnicas de tratamiento.




VOLUMEN

Gran cantidad de información difícil de procesar con los medios tradicionales



VALOR

Es necesario saber que tan pertinente es la información para los objetivos que se busca



VARIABILIDAD

Los datos provienen de múltiples soportes, herramientas y plataformas



VERACIDAD

Las empresas deben asegurarse de que los datos que están recopilando tengan validez



VELOCIDAD

los datos se generan y almacenan a una velocidad sin precedentes



ed.team/cursos/big-data-google

Big Data

- Validez: el uso de los datos debe considerar que los datos son correctos y precisos para el uso previsto.
- Volatilidad: se refiere a cuánto tiempo son válidos los datos y cuánto tiempo deben almacenarse.



VOLUMEN

Cantidad de datos que son generados y se almacenan con la finalidad de ser procesados.



VARIEDAD

Variedad de formas, tipos y fuentes de registro de datos: estructurados y no estructurados.



VELOCIDAD

Rapidez en la que los datos son creados.



VIABILIDAD

Uso eficaz de la totalidad de datos.



VERACIDAD

Grado de fiabilidad de la información.



VALOR

La transformación de los datos en información, se convierte en conocimiento para la toma de decisiones.



VISUALIZACIÓN

Representación visual de los datos para que sean legibles y accesibles. Facilita encontrar patrones en el tema a investigar.

Las 7 V's DEL BIG DATA

Cuándo usar?


Descubrir patrones ocultos,
tendencias y valores atípicos

Mejorar las decisiones
enriqueciendo la información
para los tomadores de
decisiones


Mejorar el proceso
automatizado (por ejemplo,
cadena de suministro,
transacciones comerciales)

Some sectors are positioned for greater gains from the use of big data

Historical productivity growth in the United States, 2000–08



1 See appendix for detailed definitions and metrics used for value potential index.
SOURCE: US Bureau of Labor Statistics; McKinsey Global Institute analysis



Flujo

Big Data Landscape

Log Data Apps



Vertical Apps



Business Intelligence



Analytics and Visualization



Data Providers



Analytics Infrastructure



Operational Infrastructure



Infrastructure As A Service



Structured Databases



Technologies





Bases de Datos



Ciencia de Datos



MLlib

The Machine Learning Library



Inteligencia de Negocio

Big Data Analytics



hadoop



Apache
Ambari



Apache
Zookeeper

Gobernanza

Bonitasoft

