

Universidad de Costa Rica

Facultad de Ingeniería

Escuela de Ciencias de la Computación e Informática

Bases de Datos Avanzadas

Tarea Data Lake & LakeHouse



Profesor

Luis Gustavo Esquivel

Estudiante

Brandon Trigueros Lara C17899

Semestre I

2025

Data Lake

Descripción

Un data lake es un repositorio centralizado que almacena datos en su forma nativa o cruda, ya sean objetos, archivos o flujos, sin transformación ni esquema fijo al ingreso. Esto permite guardar datos estructurados, semiestructurados y no estructurados, y ejecutar sobre ellos desde consultas SQL hasta procesamiento de Big Data y entrenamientos de modelos ML.

Ventajas

Almacenamiento masivo e indefinido: facilita la recolección y retención de todo tipo de datos sin preocuparse por el crecimiento o formatos futuros.

Flexibilidad para analítica y ML: datos en bruto pueden transformarse “on-read” para análisis SQL, exploración de datos y entrenamiento de modelos con baja latencia.

Desventajas

Gestión compleja y “data swamp”: sin buenas prácticas de gobernanza pueden proliferar datos corruptos o mal particionados, generando cuellos de botella y pérdida de confianza.

Riesgos de seguridad: concentración de datos sensibles sin control refinado puede exponer información a accesos no autorizados si no se implementan políticas adecuadas.

Ejemplos de uso

Análisis avanzado y ML: entrenar modelos de aprendizaje automático directamente sobre grandes volúmenes de logs, clics o telemetría.

Almacenamiento y análisis de IoT: ingestión continua de datos de sensores, procesamiento en tiempo real y generación de alertas.

(Ejemplos de empresas: Netflix usa un data lake para análisis de comportamiento de usuarios, y Capital One para detección de fraude sobre grandes volúmenes de transacciones).

Implementaciones

Amazon S3 (AWS Data Lake): almacenamiento de objetos escalable y económico, base de la mayoría de data lakes en AWS.

Azure Data Lake Storage: servicio de almacenamiento con namespace jerárquico, optimizado para Hadoop y analítica a gran escala.

Apache Hadoop (HDFS): plataforma open source para almacenar y procesar datos distribuidos, muy popular en implementaciones on-premise de data lakes.

Data Lakehouse

Descripción

Un lakehouse es una arquitectura que unifica data lake y data warehouse, permitiendo almacenar datos en bruto en almacenamiento de bajo costo y, al mismo tiempo, ofrecer transacciones ACID, esquemas, gobernanza y consultas de BI sobre esos mismos datos.

Ventajas

Eliminación de redundancias y reducción de costos: un único repositorio evita duplicar datos en lakes y warehouses, aprovechando almacenamiento en objetos de bajo costo y formatos abiertos.

Gobernanza y calidad mediante ACID y metadatos: capa de metadatos unificada y enforcement de esquemas mejora la fiabilidad y facilita la auditoría, el versionado y el time-travel.

Desventajas

Complejidad de implementación: requiere coordinar componentes de lago y almacén, manejar metadatos distribuidos y ajustar herramientas diversas.

Costes de mantenimiento y compatibilidad: si no se eligen formatos y motores adecuados, pueden surgir incompatibilidades y sobrecarga operativa.

Ejemplos de uso

Analítica avanzada y ML: realizar análisis predictivo y entrenamiento de modelos sobre datos crudos y curados en una sola plataforma.

Informes de BI en tiempo real: combinar datos transaccionales y de streaming para dashboards actualizados al instante.

Implementaciones

Databricks Lakehouse Platform (comercial): entorno colaborativo con notebooks, MLflow y Delta Lake integrado.

Snowflake Data Lakehouse (comercial): servicio gestionado que implementa patrones lakehouse sobre Iceberg o Polaris Catalog para transacciones y BI.

Apache Iceberg (open source): formato de tablas de alto rendimiento con transacciones, versionado y compatibilidad multi-engine.

Referencias

Amazon Web Services. (2017, noviembre 27). *What is a data lake?* AWS Big Data Blog. <https://aws.amazon.com/big-data/datalakes-and-analytics/what-is-a-data-lake/>

Amazon Web Services. (n.d.). *Amazon Simple Storage Service (S3) [Data sheet]*. <https://aws.amazon.com/s3/>

Microsoft. (2018, agosto 29). *Announcing Azure Data Lake Storage Gen2*. Microsoft Tech Community. <https://techcommunity.microsoft.com/t5/azure-storage-blog/announcing-azure-data-lake-storage-gen2/ba-p/303422>

Microsoft Azure. (2023). *Azure Data Lake Storage Gen2*. Microsoft Azure. <https://azure.microsoft.com/en-us/services/storage/data-lake-storage/>

The Apache Software Foundation. (n.d.). *Hadoop Distributed File System (HDFS) Design*. <https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html>

Netflix Technology Blog. (2016, marzo 25). *The evolution of our data platform: Building a data lake at Netflix*. Netflix Technology Blog.
<https://netflixtechblog.com/the-evolution-of-our-data-platform-building-a-data-lake-at-netflix-191cf11517b4>

Capital One. (2017). *Building a data lake at Capital One*. Capital One DevExchange.
<https://developer.capitalone.com/blogs/capital-one-cloud/data-lake-at-capital-one>

Databricks. (2021). *What is the Lakehouse?* Databricks.
<https://databricks.com/product/databricks-lakehouse-platform>

Snowflake Inc. (2022). *Introducing Lakehouse on Snowflake*. Snowflake Blog.
<https://www.snowflake.com/blog/introducing-lakehouse-on-snowflake/>

The Apache Software Foundation. (2023). *Apache Iceberg: High-performance table format for huge analytic datasets*. <https://iceberg.apache.org/>